

Repaso de R y fundamentos de Quarto

Bioestadística avanzada con R · Semana 1

Edsaúl Emilio Pérez Guerrero

17 de agosto de 2026

Contenido

1	Presentación de la sesión	2
1.1	Objetivo de aprendizaje	2
1.2	Productos de la sesión	2
1.3	Organización sugerida de las dos horas	3
2	¿Qué significa que un análisis sea reproducible?	3
3	Organización del proyecto	3
4	Anatomía de un documento Quarto	4
5	Preparación del entorno	5
6	Repaso selectivo de R	5
6.1	R como calculadora	5
6.2	Objetos y asignación	6
6.3	Vectores	6
6.4	Valores faltantes	7
6.5	Clases de objetos	8
7	Creación de los datos de práctica	8
8	Exploración inicial de los datos	10
8.1	Pausa de interpretación	12
9	Transformación con tidyverse	12
9.1	Seleccionar variables	12
9.2	Filtrar observaciones	13

9.3	Crear o modificar variables	13
9.4	Resumir por grupos	14
10	Presentación de resultados	14
10.1	Tabla descriptiva	14
10.2	Visualización	15
10.3	Interpretación de la figura	16
11	Actividad integradora	16
11.1	Desarrollo	17
11.1.1	Discusión	17
12	Renderización del reporte	17
13	Lista de verificación	18
14	Cierre	18
15	Información de la sesión de R	18

1. Presentación de la sesión

En esta sesión repasaremos los fundamentos de R mientras construimos un reporte reproducible con Quarto. El propósito no es revisar exhaustivamente la sintaxis del lenguaje, sino recuperar las herramientas necesarias para organizar, analizar, interpretar y comunicar datos biomédicos.

Trabajaremos en un solo documento que integrará texto, código, resultados, tablas y figuras. Al finalizar, este documento se convertirá en un archivo PDF que podrá compartirse sin necesidad de entregar por separado el código y la interpretación.

1.1. Objetivo de aprendizaje

Al finalizar la sesión, el estudiante será capaz de crear y renderizar un documento Quarto que importe, explore, transforme y resuma una base de datos mediante R y `tidyverse`, incorporando código, resultados e interpretaciones en un reporte reproducible.

1.2. Productos de la sesión

Al terminar la actividad, cada estudiante contará con:

- un proyecto organizado de R;

- un documento fuente en formato `.qmd`;
- un análisis básico y reproducible de datos;
- una tabla y una figura acompañadas de su interpretación;
- un reporte final en formato PDF.

1.3. Organización sugerida de las dos horas

Tiempo	Actividad
0–15 min	Proyectos y análisis reproducible
15–35 min	Anatomía de un documento Quarto
35–60 min	Repaso selectivo de objetos y operaciones en R
60–90 min	Importación, exploración y transformación con <code>tidyverse</code>
90–110 min	Construcción de tablas, figuras e interpretación
110–120 min	Renderización a PDF, revisión y cierre

2. ¿Qué significa que un análisis sea reproducible?

Un análisis es reproducible cuando otra persona —o nosotros mismos en el futuro— puede reconstruir los resultados a partir de los datos y del código documentado. Esto requiere que la importación, la limpieza, las transformaciones, el análisis y la presentación de resultados formen parte de un flujo explícito.

En un reporte reproducible:

- los datos originales se conservan sin modificaciones manuales;
- las transformaciones quedan registradas como código;
- las tablas y figuras se generan automáticamente;
- las decisiones analíticas se explican por escrito;
- el documento puede volver a ejecutarse cuando cambian los datos.

i Idea central

Un documento Quarto no es solamente un archivo de código. Es un reporte en el que conviven el razonamiento científico, el código, los resultados y su interpretación.

3. Organización del proyecto

Para esta práctica se propone la siguiente estructura:

```
semana-01/  
  reporte_semana01.qmd  
  datos/  
    pacientes.csv  
  scripts/  
  figuras/
```

El archivo `.qmd` se guarda en la carpeta principal. Los datos se colocan dentro de `datos/`. De esta forma podemos utilizar rutas relativas, por ejemplo:

```
readr::read_csv("datos/pacientes.csv")
```

Debe evitarse el uso de rutas absolutas como:

```
# No ejecutar: solamente es un ejemplo  
readr::read_csv("/Users/mi_nombre/Documentos/curso/pacientes.csv")
```

Las rutas absolutas dependen de una computadora y de un usuario específicos. Las rutas relativas parten de la carpeta del proyecto y facilitan que el análisis funcione en otros equipos.

4. Anatomía de un documento Quarto

Un documento Quarto contiene tres elementos principales:

1. **Encabezado YAML:** define el título, autor, fecha y formato de salida.
2. **Texto en Markdown:** contiene explicaciones, preguntas e interpretaciones.
3. **Bloques de código:** ejecutan el análisis y producen resultados.

El encabezado de este documento se encuentra entre dos líneas de guiones al inicio del archivo. Un bloque de código de R se escribe de la siguiente manera:

```
::: {.cell}  
  
```.r .cell-code  
2 + 2
~~~  
  
::: {.cell-output .cell-output-stdout}
```

```
~~~  
[1] 4
~~~  
  
:::  
:::
```

Al renderizar el documento, Quarto ejecuta los bloques en orden e incorpora sus resultados al PDF.

#### Buena práctica

El documento debe poder ejecutarse desde el inicio hasta el final en una sesión limpia de R. No debemos depender de objetos creados previamente en la consola.

## 5. Preparación del entorno

Comenzamos cargando los paquetes que utilizaremos. El paquete **tidyverse** reúne herramientas para importar, transformar, resumir y visualizar datos.

```
library(tidyverse)
```

Si el paquete no está instalado, se instala una sola vez desde la consola:

```
install.packages("tidyverse")
```

La instalación no debe incluirse como parte del análisis cotidiano, pues intentaría repetirse cada vez que se renderice el documento.

## 6. Repaso selectivo de R

### 6.1. R como calculadora

R permite realizar operaciones aritméticas y utilizar funciones matemáticas.

```
2 + 3
```

```
[1] 5
```

```
10 / 4
```

```
[1] 2.5
```

```
2^3
```

```
[1] 8
```

```
sqrt(25)
```

```
[1] 5
```

```
log(10)
```

```
[1] 2.302585
```

## 6.2. Objetos y asignación

El operador `<-` asigna un valor a un objeto.

```
edad <- 42
peso_kg <- 71.5
estatura_m <- 1.68

imc <- peso_kg / estatura_m^2
imc
```

```
[1] 25.33305
```

Los nombres claros permiten entender el análisis sin depender de comentarios adicionales. Conviene evitar nombres ambiguos como `x`, `dato1` o `final_final`.

## 6.3. Vectores

Un vector reúne varios valores del mismo tipo.

```
edades <- c(34, 51, 46, 29, 63)
```

```
length(edades)
```

```
[1] 5
```

```
mean(edades)
```

```
[1] 44.6
```

```
median(edades)
```

```
[1] 46
```

```
sd(edades)
```

```
[1] 13.57571
```

```
range(edades)
```

```
[1] 29 63
```

## 6.4. Valores faltantes

R representa los valores faltantes mediante NA. Muchas funciones requieren indicar explícitamente cómo manejarlos.

```
biomarcador <- c(12.1, 10.8, NA, 13.4, 11.7)
```

```
is.na(biomarcador)
```

```
[1] FALSE FALSE TRUE FALSE FALSE
```

```
sum(is.na(biomarcador))
```

```
[1] 1
```

```
mean(biomarcador, na.rm = TRUE)
```

```
[1] 12
```

### ! Interpretación

Usar `na.rm = TRUE` elimina temporalmente los valores faltantes para realizar el cálculo; no constituye un método de imputación ni resuelve el mecanismo que produjo la ausencia de datos.

## 6.5. Clases de objetos

La clase de una variable determina las operaciones que pueden realizarse con ella.

```
class(42)
```

```
[1] "numeric"
```

```
class("control")
```

```
[1] "character"
```

```
class(TRUE)
```

```
[1] "logical"
```

```
class(as.Date("2026-08-17"))
```

```
[1] "Date"
```

## 7. Creación de los datos de práctica

Para que este documento pueda ejecutarse desde el inicio, construiremos una pequeña base de datos simulada. En una práctica posterior sustituiremos este bloque por la importación de un archivo externo.



```
pacientes <- tibble(
  id = 1:20,
  grupo = rep(c("Control", "Tratamiento"), each = 10),
  sexo = rep(c("Mujer", "Hombre"), times = 10),
  edad = c(34, 51, 46, 29, 63, 42, 38, 55, 47, 60,
            36, 49, 41, 32, 58, 45, 39, 53, 44, 57),
  imc = c(23.1, 27.4, 25.8, 22.6, 30.2, 26.1, NA, 28.7, 24.9, 29.4,
           22.8, 25.6, 24.2, 21.9, 27.5, 23.7, 24.5, NA, 23.9, 26.8),
  biomarcador = c(12.4, 14.1, 13.2, 11.8, 15.7, 13.6, 12.9, 15.1, 13.5, 14.8,
                  10.9, 12.3, 11.4, 10.7, 13.1, 11.6, 11.2, 12.8, 11.5, 12.4)
)
```

```
pacientes
```

```
# A tibble: 20 x 6
```

	id	grupo	sexo	edad	imc	biomarcador
	<int>	<chr>	<chr>	<dbl>	<dbl>	<dbl>
1	1	Control	Mujer	34	23.1	12.4
2	2	Control	Hombre	51	27.4	14.1
3	3	Control	Mujer	46	25.8	13.2
4	4	Control	Hombre	29	22.6	11.8
5	5	Control	Mujer	63	30.2	15.7
6	6	Control	Hombre	42	26.1	13.6
7	7	Control	Mujer	38	NA	12.9
8	8	Control	Hombre	55	28.7	15.1
9	9	Control	Mujer	47	24.9	13.5
10	10	Control	Hombre	60	29.4	14.8
11	11	Tratamiento	Mujer	36	22.8	10.9
12	12	Tratamiento	Hombre	49	25.6	12.3
13	13	Tratamiento	Mujer	41	24.2	11.4
14	14	Tratamiento	Hombre	32	21.9	10.7
15	15	Tratamiento	Mujer	58	27.5	13.1
16	16	Tratamiento	Hombre	45	23.7	11.6
17	17	Tratamiento	Mujer	39	24.5	11.2
18	18	Tratamiento	Hombre	53	NA	12.8
19	19	Tratamiento	Mujer	44	23.9	11.5
20	20	Tratamiento	Hombre	57	26.8	12.4

Para practicar la importación desde un archivo, podemos guardar esta tabla como CSV. Esta instrucción se ejecuta una sola vez:

```
write_csv(pacientes, "datos/pacientes.csv", na = "")
```

Posteriormente, la importación se realiza así:

```
pacientes <- read_csv("datos/pacientes.csv", show_col_types = FALSE)
```

## 8. Exploración inicial de los datos

Antes de aplicar cualquier modelo debemos conocer la estructura y la calidad de los datos.

```
glimpse(pacientes)
```

```
Rows: 20
Columns: 6
$ id      <int> 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, 17,~
$ grupo   <chr> "Control", "Control", "Control", "Control", "Control", "Co~
$ sexo    <chr> "Mujer", "Hombre", "Mujer", "Hombre", "Mujer", "Hombre", "~
$ edad    <dbl> 34, 51, 46, 29, 63, 42, 38, 55, 47, 60, 36, 49, 41, 32, 58~
$ imc     <dbl> 23.1, 27.4, 25.8, 22.6, 30.2, 26.1, NA, 28.7, 24.9, 29.4, ~
$ biomarcador <dbl> 12.4, 14.1, 13.2, 11.8, 15.7, 13.6, 12.9, 15.1, 13.5, 14.8~
```

```
head(pacientes)
```

```
# A tibble: 6 x 6
  id grupo  sexo  edad  imc biomarcador
<int> <chr>  <chr> <dbl> <dbl>      <dbl>
1     1 Control Mujer   34  23.1      12.4
2     2 Control Hombre  51  27.4      14.1
3     3 Control Mujer   46  25.8      13.2
4     4 Control Hombre  29  22.6      11.8
5     5 Control Mujer   63  30.2      15.7
6     6 Control Hombre  42  26.1      13.6
```

```
dim(pacientes)
```

```
[1] 20  6
```

```
summary(pacientes)
```

id	grupo	sexo	edad
Min. : 1.00	Length:20	Length:20	Min. :29.00
1st Qu.: 5.75	Class :character	Class :character	1st Qu.:38.75
Median :10.50	Mode :character	Mode :character	Median :45.50
Mean :10.50			Mean :45.95
3rd Qu.:15.25			3rd Qu.:53.50
Max. :20.00			Max. :63.00

imc	biomarcador
Min. :21.90	Min. :10.70
1st Qu.:23.75	1st Qu.:11.57
Median :25.25	Median :12.60
Mean :25.51	Mean :12.75
3rd Qu.:27.25	3rd Qu.:13.53
Max. :30.20	Max. :15.70
NA's :2	

La exploración inicial debe responder, al menos, las siguientes preguntas:

- ¿Cuál es la unidad de observación?
- ¿Cuántas observaciones y variables existen?
- ¿Qué representa cada variable?
- ¿Las clases de las variables son correctas?
- ¿Existen valores faltantes o valores poco plausibles?
- ¿Hay identificadores duplicados?

```
pacientes |>
  summarise(
    n = n(),
    identificadores_unicos = n_distinct(id),
    faltantes_imc = sum(is.na(imc)),
    faltantes_biomarcador = sum(is.na(biomarcador))
  )
```

```
# A tibble: 1 x 4
      n identificadores_unicos faltantes_imc faltantes_biomarcador
  <int>                <int>         <int>                <int>
1    20                  20             2                      0
```

## 8.1. Pausa de interpretación

Escriba dos o tres oraciones sobre la estructura y la calidad de la base. No se limite a copiar los resultados: explique qué implican para el análisis.

**Interpretación del estudiante:** Reemplace este texto con su interpretación.

## 9. Transformación con tidyverse

### 9.1. Seleccionar variables

```
pacientes |>
  select(id, grupo, edad, biomarcador)
```

# A tibble: 20 x 4

	id	grupo	edad	biomarcador
	<int>	<chr>	<dbl>	<dbl>
1	1	Control	34	12.4
2	2	Control	51	14.1
3	3	Control	46	13.2
4	4	Control	29	11.8
5	5	Control	63	15.7
6	6	Control	42	13.6
7	7	Control	38	12.9
8	8	Control	55	15.1
9	9	Control	47	13.5
10	10	Control	60	14.8
11	11	Tratamiento	36	10.9
12	12	Tratamiento	49	12.3
13	13	Tratamiento	41	11.4
14	14	Tratamiento	32	10.7
15	15	Tratamiento	58	13.1
16	16	Tratamiento	45	11.6
17	17	Tratamiento	39	11.2
18	18	Tratamiento	53	12.8
19	19	Tratamiento	44	11.5
20	20	Tratamiento	57	12.4

## 9.2. Filtrar observaciones

```
pacientes |>
  filter(edad >= 50)
```

# A tibble: 7 x 6

	id	grupo	sexo	edad	imc	biomarcador
	<int>	<chr>	<chr>	<dbl>	<dbl>	<dbl>
1	2	Control	Hombre	51	27.4	14.1
2	5	Control	Mujer	63	30.2	15.7
3	8	Control	Hombre	55	28.7	15.1
4	10	Control	Hombre	60	29.4	14.8
5	15	Tratamiento	Mujer	58	27.5	13.1
6	18	Tratamiento	Hombre	53	NA	12.8
7	20	Tratamiento	Hombre	57	26.8	12.4

## 9.3. Crear o modificar variables

```
pacientes <- pacientes |>
  mutate(
    grupo = factor(grupo, levels = c("Control", "Tratamiento")),
    sexo = factor(sexo),
    edad_centrada = edad - mean(edad, na.rm = TRUE),
    imc_alto = if_else(imc >= 25, "Sí", "No", missing = NA_character_)
  )

glimpse(pacientes)
```

Rows: 20

Columns: 8

\$ id	<int> 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, 1~
\$ grupo	<fct> Control, Control, Control, Control, Control, Control, Co~
\$ sexo	<fct> Mujer, Hombre, Mujer, Hombre, Mujer, Hombre, Mujer, Homb~
\$ edad	<dbl> 34, 51, 46, 29, 63, 42, 38, 55, 47, 60, 36, 49, 41, 32, ~
\$ imc	<dbl> 23.1, 27.4, 25.8, 22.6, 30.2, 26.1, NA, 28.7, 24.9, 29.4~
\$ biomarcador	<dbl> 12.4, 14.1, 13.2, 11.8, 15.7, 13.6, 12.9, 15.1, 13.5, 14~
\$ edad_centrada	<dbl> -11.95, 5.05, 0.05, -16.95, 17.05, -3.95, -7.95, 9.05, 1~
\$ imc_alto	<chr> "No", "Sí", "Sí", "No", "Sí", "Sí", NA, "Sí", "No", "Sí"~

## 9.4. Resumir por grupos

```
resumen_grupos <- pacientes |>
  group_by(grupo) |>
  summarise(
    n = n(),
    edad_media = mean(edad, na.rm = TRUE),
    edad_de = sd(edad, na.rm = TRUE),
    biomarcador_media = mean(biomarcador, na.rm = TRUE),
    biomarcador_de = sd(biomarcador, na.rm = TRUE),
    .groups = "drop"
  )

resumen_grupos
```

```
# A tibble: 2 x 6
  grupo          n edad_media edad_de biomarcador_media biomarcador_de
<fct>    <int>    <dbl>   <dbl>          <dbl>          <dbl>
1 Control      10     46.5    11.1             13.7            1.23
2 Tratamiento  10     45.4     8.78             11.8            0.814
```

El operador `|>` se lee como “luego”. Permite expresar el flujo del análisis de izquierda a derecha: partimos de una base, la agrupamos y después calculamos los resúmenes.

## 10. Presentación de resultados

### 10.1. Tabla descriptiva

```
knitr::kable(
  resumen_grupos,
  digits = 2,
  col.names = c(
    "Grupo", "n", "Edad: media", "Edad: DE",
    "Biomarcador: media", "Biomarcador: DE"
  )
)
```

Tabla 2: Resumen descriptivo por grupo de estudio.

Grupo	n	Edad: media	Edad: DE	Biomarcador: media	Biomarcador: DE
Control	10	46.5	11.07	13.71	1.23
Tratamiento	10	45.4	8.78	11.79	0.81

Una tabla debe poder comprenderse sin inspeccionar el código. Necesita un título informativo, nombres claros, unidades cuando correspondan y un número razonable de decimales.

## 10.2. Visualización

```
ggplot(pacientes, aes(x = grupo, y = biomarcador, fill = grupo)) +
  geom_boxplot(width = 0.55, alpha = 0.75, show.legend = FALSE) +
  geom_jitter(width = 0.08, alpha = 0.65, show.legend = FALSE) +
  labs(
    x = "Grupo de estudio",
    y = "Biomarcador (unidades)"
  ) +
  theme_minimal(base_size = 11)
```




Figura 1: Distribución del biomarcador según el grupo de estudio.

### 10.3. Interpretación de la figura

Describe el patrón observado sin afirmar que existe una diferencia estadísticamente significativa. Considere la tendencia central, la dispersión, el posible solapamiento entre grupos y el tamaño de la muestra.

**Interpretación del estudiante:** Reemplace este texto con una interpretación de tres a cinco oraciones.

## 11. Actividad integradora

A partir de la base `pacientes`, realice las siguientes tareas:

1. Compruebe si existen valores faltantes en cada variable.
2. Calcule la edad mediana y el rango intercuartílico por sexo.
3. Calcule la media y la desviación estándar del biomarcador por grupo y sexo.



4. Construya una figura que muestre la relación entre edad y biomarcador, diferenciando los grupos mediante color.
5. Añada títulos y etiquetas claras a la tabla y a la figura.
6. Escriba un párrafo breve que interprete los resultados y señale al menos una limitación.

### 11.1. Desarrollo

Utilice los siguientes bloques como punto de partida. Modifique el código donde sea necesario.

```
# Escriba aquí su código
```

```
# Escriba aquí su código
```

```
# Escriba aquí su código
```

#### 11.1.1. Discusión

**Discusión del estudiante:** Presente los principales hallazgos, distinga la descripción de la inferencia y señale una limitación del análisis.

## 12. Renderización del reporte

Antes de generar el PDF:

1. guarde el archivo `.qmd`;
2. reinicie la sesión de R si desea comprobar la reproducibilidad;
3. utilice el botón **Render**;
4. revise que no existan errores;
5. verifique títulos, tablas, figuras y saltos de página;
6. abra el PDF final y compruebe que sea legible.

Para generar archivos PDF, Quarto necesita una distribución de LaTeX. Puede instalarse TinyTeX desde la terminal con:

```
quarto install tinytex
```

Esta instalación se realiza una sola vez.

## 13. Lista de verificación

- ☐ El documento se ejecuta desde el inicio hasta el final.
- ☐ Todas las librerías necesarias se cargan en el documento.
- ☐ Los datos se leen mediante una ruta relativa.
- ☐ Las transformaciones están documentadas mediante código.
- ☐ La tabla tiene un título y nombres comprensibles.
- ☐ La figura tiene título, ejes y unidades apropiadas.
- ☐ Los resultados están acompañados de interpretación.
- ☐ El archivo PDF se generó correctamente.

## 14. Cierre

En esta sesión utilizamos R y Quarto como componentes de un mismo flujo analítico. El objetivo no fue únicamente obtener resultados, sino construir un documento que permita comprender de dónde provienen, cómo se calcularon y qué significan.

En la segunda sesión trabajaremos con un script deliberadamente desorganizado. Identificaremos problemas de rutas, nombres, repetición, transformaciones manuales y resultados sin interpretar; después lo convertiremos en un proyecto reproducible.

## 15. Información de la sesión de R

Registrar las versiones del software y de los paquetes ayuda a documentar el entorno en el que se realizó el análisis.

```
sessionInfo()
```

```
R version 4.5.1 (2025-06-13)
Platform: aarch64-apple-darwin20
Running under: macOS Tahoe 26.5.2
```

```
Matrix products: default
```

```
BLAS:   /Library/Frameworks/R.framework/Versions/4.5-arm64/Resources/lib/libRblas.0.dylib
LAPACK: /Library/Frameworks/R.framework/Versions/4.5-arm64/Resources/lib/libRlapack.dylib;
```

```
locale:
```

```
[1] en_US.UTF-8/en_US.UTF-8/en_US.UTF-8/C/en_US.UTF-8/en_US.UTF-8
```

```
time zone: America/New_York
```

tzcode source: internal

attached base packages:

[1] stats graphics grDevices utils datasets methods base

other attached packages:

[1] lubridate\_1.9.5 forcats\_1.0.1 stringr\_1.6.0 dplyr\_1.2.1  
[5] purrr\_1.2.2 readr\_2.2.0 tidyr\_1.3.2 tibble\_3.3.1  
[9] ggplot2\_4.0.2 tidyverse\_2.0.0

loaded via a namespace (and not attached):

[1] gtable\_0.3.6 jsonlite\_2.0.0 compiler\_4.5.1 tidyselect\_1.2.1  
[5] scales\_1.4.0 yaml\_2.3.12 fastmap\_1.2.0 R6\_2.6.1  
[9] labeling\_0.4.3 generics\_0.1.4 knitr\_1.51 pillar\_1.11.1  
[13] RColorBrewer\_1.1-3 tzdb\_0.5.0 rlang\_1.2.0 utf8\_1.2.6  
[17] stringi\_1.8.7 xfun\_0.57 S7\_0.2.1 otel\_0.2.0  
[21] timechange\_0.4.0 cli\_3.6.6 withr\_3.0.2 magrittr\_2.0.5  
[25] digest\_0.6.39 grid\_4.5.1 rstudioapi\_0.18.0 hms\_1.1.4  
[29] lifecycle\_1.0.5 vctrs\_0.7.3 evaluate\_1.0.5 glue\_1.8.1  
[33] farver\_2.1.2 rmarkdown\_2.31 tools\_4.5.1 pkgconfig\_2.0.3  
[37] htmltools\_0.5.9