25 Análisis estratificado y regresión logística

$$\sum_{i=1}^{N} x_i \qquad \frac{\sum_{i=1}^{N} x_i}{N} \qquad \sigma^2 = \frac{\sum_{i=1}^{N} (x_i - \mu)^2}{N}$$

DISEÑOS EPIDEMIOLÓGICOS ANALÍTICOS

Los diseños analíticos básicos en epidemiología son dos: los que primero identifican la condición de exposición y luego miden la frecuencia del evento (estudios de cohorte, ensayos clínicos), y los que primero identifican la condición del evento y luego buscan la condición de exposición (estudios de casos y controles). A pesar de que el proceso muestral de estos diseños es diferente, ambos pueden explicarse a partir de un diseño de cohorte.

Ejemplo explicativo 25-1

Consideremos una población en riesgo de desarrollar diabetes mellitus formada por dos subgrupos: uno de 10 000 expuestos a "X" y el otro de 50 000 sin esa exposición. Asumamos que, entre los expuestos a "X", 30 enfermaron de diabetes mellitus en el transcurso de un año, mientras que 50 enfermaron entre los no expuestos. En estas condiciones, el riesgo relativo sería igual a

$$RR = \frac{30/10000}{50/50000} = 3$$

Si un investigador tuviera interés en estudiar esa asociación en la población con un diseño de cohorte por medio de dos muestras del mismo tamaño (una de expuestos y otra de no expuestos), con una confianza de 95% y un poder de 80%, el tamaño de cada grupo sería de 8 804, es decir, una muestra total de 16 608 sujetos, a los que tendría que seguir durante todo un año.

Por otra parte, el investigador podría utilizar un diseño de casos y controles donde captaría a los 80 enfermos (casos) que se presentan durante un año en la población de estudio y los compararía con una muestra de los que no enfermaron durante ese año (controles). A cada sujeto en estudio le preguntaría si estuvo expuesto a "X" o no. Mediante este diseño, una muestra con el mismo nivel de confianza y poder que la calculada para el estudio de cohorte descrito líneas arriba, y que fuera capaz de identificar un odds ratio igual o mayor de 3.0, sólo demandaría 80 casos y 80 controles.

Al realizar su estudio, encontraría 80 casos: todos los que enfermaron durante el año de estudio en la población de interés a la que se refiere este ejemplo explicativo. De ellos, 30 habrían estado expuestos a "X" y 50 no. Como el investigador sólo estudiaría una muestra de los que no enfermaron, tendría que seleccionar 80 controles entre los 59 920 sanos (16.6% expuestos, 83.4% no expuestos). Si la muestra de 80 controles sigue las leyes de la probabilidad, en la muestra de 80 controles encontraría 13 expuestos y 67 no expuestos. Con estos datos podría presentar los números que se muestran en el cuadro 25-1, a partir de los cuales podría calcular el odds ratio mediante

$$\varphi = \frac{ad}{bc} = \frac{30 \times 67}{13 \times 50} = 3.09$$

un resultado que no es igual al obtenido mediante el riesgo relativo, pero que sí está muy próximo.

Cuadro 25-1. Datos hipotéticos de un estudio de casos y controles

Expuestos a "X"	Casos	Controles
Sí	30	13
No	50	67

© Editorial El Manual Moderno Fotocopiar sin autorización es un delito.

ODDS RATIO COMO UNA APROXIMACIÓN AL RIESGO RELATIVO

Es necesario hacer notar que el odds ratio no es igual al riesgo relativo, pero, cuando se cumplen ciertas condiciones, los dos números son muy semejantes. Por ello, algunos investigadores los utilizan indistintamente.

Para entender la relación que existe entre ambos números, es necesario revisar con cuidado el cuadro 25-2. Obsérvese que, cuando la frecuencia del fenómeno (incidencia o prevalencia) en expuestos y no expuestos es la misma, el riesgo relativo y el odds ratio tienen el mismo valor: 1.0. Siempre que la frecuencia del fenómeno estudiado en los grupos es diferente, el odds ratio estará más alejado de 1.0 que el riesgo relativo. Cuando la frecuencia es diferente pero el evento es raro, los dos estimadores son diferentes pero muy cercanos. La mayoría de los epidemiólogos considera que un evento es raro cuando la frecuencia del fenómeno es menor de 10%. Por otro lado, cuando el fenómeno estudiado es frecuente, el odds ratio puede ser muy diferente al riesgo relativo, particularmente cuando los dos estimadores se alejan de 1.0.

ANÁLISIS DE DATOS

El análisis de los datos obtenidos en un estudio epidemiológico analítico se desarrolla en tres etapas:

1. Análisis inicial, donde el investigador tratará de mostrar que los dos grupos en el estudio son comparables.
2. Análisis crudo, que mostrará la fuerza de asociación que existe entre la variable independiente y la variable dependiente.
3. Análisis multivariado, que busca identificar interacciones o ajustar factores de confusión que pudieran influir en los resultados.

Análisis inicial

Esta primera etapa del análisis consiste básicamente en mostrar que los grupos son comparables. Para hacerlo, las frecuencias se presentan de manera tabular, de tal manera que las variables y sus categorías estén acompañadas de las

Cuadro 25-2. Relación numérica entre riesgo relativo y odds ratio

Frecuencia en no expuestos		Frecuencia en expuestos								
		0.01	0.03	0.05	0.06	0.10	0.15	0.20	0.30	0.40
0.01	RR	1.000	3.000	5.000	6.000	10.000	15.000	20.000	30.000	40.000
	OR	1.000	**3.062**	**5.211**	**6.319**	**11.000**	**17.471**	**24.750**	**42.429**	**66.000**
0.03	RR	0.333	1.000	1.667	2.000	3.333	5.000	6.667	10.000	13.333
	OR	**0.327**	1.000	**1.702**	**2.064**	**3.593**	**5.706**	**8.083**	**13.857**	**21.556**
0.05	RR	0.200	0.600	1.000	1.200	2.000	3.000	4.000	6.000	8.000
	OR	**0.192**	**0.588**	1.000	**1.213**	**2.111**	**3.353**	**4.750**	**8.143**	**12.667**
0.06	RR	0.167	0.500	0.833	1.000	1.667	2.500	3.333	5.000	6.667
	OR	**0.158**	**0.485**	**0.825**	1.000	**1.741**	**2.765**	**3.917**	**6.714**	**10.444**
0.10	RR	0.100	0.300	0.500	0.600	1.000	1.500	2.000	3.000	4.000
	OR	**0.091**	**0.278**	**0.474**	**0.574**	1.000	**1.588**	**2.250**	3.857	6.000
0.15	RR	0.067	0.200	0.333	0.400	0.667	1.000	1.333	2.000	2.667
	OR	0.057	0.175	0.298	0.362	0.630	1.000	**1.417**	**2.429**	**3.778**
0.20	RR	0.050	0.150	0.250	0.300	0.500	0.750	1.000	1.500	2.000
	OR	0.040	0.124	0.211	**0.255**	**0.444**	**0.706**	1.000	**1.714**	**2.667**
0.30	RR	0.033	0.100	0.167	0.200	0.333	0.500	0.667	1.000	1.333
	OR	0.024	**0.072**	**0.123**	**0.149**	**0.259**	**0.412**	**0.583**	1.000	**1.556**
0.40	RR	0.025	0.075	0.125	0.150	0.250	0.375	0.500	0.750	1.000
	OR	**0.015**	**0.046**	**0.079**	**0.096**	**0.167**	**0.265**	**0.375**	**0.643**	1.000

© Editorial El Manual Moderno Fotocopiar sin autorización es un delito.

frecuencias absolutas y los porcentajes de columna para cada categoría de la variable dependiente, tal como se muestra en el **cuadro 25-3**. Entre las variables que se exploran en esta etapa del análisis se encuentran las características sociodemográficas y algunas otras variables que no se incluyen en el objetivo principal del análisis. Algunos investigadores suelen acompañar este cuadro con intervalos de confianza o con valores de significancia, pero no es absolutamente necesario. De hecho, en ocasiones pueden distraer del objetivo que tiene este primer cuadro.

Ejemplo explicativo 25-2

Compárense los **cuadros 25-3** y **25-4**: los dos cuadros son semejantes en cuanto a las variables descritas, pero no en cuanto a sus frecuencias absolutas y relativas. Los porcentajes del **cuadro 25-3** nos hacen ver que, en lo referente a sexo, grupo de edad y nivel socioeconómico, los grupos que se están comparando (enfermos, no enfermos) son muy semejantes (las diferencias entre uno y otro grupo no van más allá de 3%), y las pequeñas diferencias observadas no son estadísticamente significativas ($p > 0.05$). Sin embargo, el **cuadro 25-4** muestra que los grupos de enfermos y no enfermos tienen grandes diferencias en sus porcentajes para las tres variables tabuladas (en algunas categorías, la diferencia es superior a 15.0%). Si estas tres variables (sexo, grupo de edad y nivel socioeconómico) estuvieran asociadas con el factor de riesgo, podrían confundir la asociación entre éste y la variable dependiente; no obstante, una prueba de significancia (chi-cuadrada) en las variables del **cuadro 25-4** mostrará que las diferencias observadas no son estadísticamente significativas ($p > 0.05$).

Análisis crudo

En la segunda etapa del análisis, el objetivo es mostrar la fuerza de asociación que existe entre una variable independiente y una variable dependiente. Los datos también se presentan de manera tabular, como en el **cuadro 25-3**, pero se le agregan dos columnas más, como se muestra en el **cuadro 25-5**: una para mostrar la diferencia (riesgo atribuible, RA) o la razón (riesgo relativo, RR; odds ratio, OR) en que se basa la estimación y otra para los intervalos de confianza. La tendencia actual favorece la presentación de los intervalos de confianza en lugar de los valores de significancia, pero cuando no se puedan calcular intervalos de confianza, se podrán presentar los valores de *p*.

Cuadro 25-3. Presentación de datos de un estudio de casos y controles

	Enfermos		No enfermos	
	n	%	n	%
Sexo				
Masculino	30	60.0	59	59.0
Femenino	20	40.0	41	41.0
Grupo de edad				
20 a 29	10	20.0	19	19.0
30 a 39	14	28.0	27	27.0
40 a 49	26	52.0	54	54.0
Nivel socioeconómico				
Alto	15	30.0	28	28.0
Medio	15	30.0	33	33.0
Bajo	20	40.0	39	39.0

Cuadro 25-4. Presentación de datos de un estudio de casos y controles

Variable	Enfermos		No enfermos	
	n	%	n	%
Sexo				
Masculino	35	70.0	54	54.0
Femenino	15	30.0	46	46.0
Grupo de edad				
20 a 29	12	24.0	10	10.0
30 a 39	15	30.0	30	30.0
40 a 49	23	46.0	60	60.0
Nivel socioeconómico				
Alto	15	30.0	15	15.0
Medio	14	28.0	25	25.0
Bajo	21	42.0	60	60.0

Análisis ajustado mediante estratificación

El análisis estratificado se puede realizar cuando la variable dependiente es dicotómica y las variables independientes son cualitativas (casi siempre nominales). Para hacerlo, procedemos de la siguiente manera:

1. Definimos la asociación a estudiar mediante la identificación de una variable independiente o factor de riesgo (como consumo de tabaco durante el embarazo [sí, no]) y una variable dependiente o efecto (como producto con bajo peso al nacer [sí, no]). Con estas dos variables se conforma un cuadro de contingencia 2 x 2.
2. Luego se tabulan los datos de tal manera que se presente un cuadro de contingencia para cada categoría de la covariable (o combinación de covariables) de interés. Cada uno de estos cuadros de contingencia se designará como estrato, como se muestra en el **cuadro 25-6**. Si se tuviera interés en estratificar por una variable que tenga dos categorías, entonces tendríamos dos cuadros 2 x 2, uno para cada nivel de la covariable: el estrato 1 estaría formado por todos los sujetos que tengan la categoría "0" de la covariable y en el estrato 2 estarían todos los

© Editorial El Manual Moderno Fotocopiar sin autorización es un delito.

Cuadro 25-5. Presentación de datos de un estudio de casos y controles

Variable	Casos		Controles		OR	IC 95%
	n	%	n	%		
Edad						
≥ 20 años	99	66.4	77	51.0	1.9	1.2 a 3.0
< 20 años	50	33.6	74	49.0	1.0	
Tabaco						
Fumadora	89	59.7	33	27.9	5.3	3.2 a 8.8
No fumadora	60	40.3	118	78.1	1.0	
Consumo de alcohol						
≥ 12 g/día	35	23.5	15	9.9	2.8	1.4 a 5.4
< 12 g/día	114	76.6	136	90.1	1.0	
Gen						
Sí	60	40.3	28	18.5	3.0	1.8 a 5.0
No	89	59.7	123	81.5	1.0	

sujetos que tuvieran la categoría "1" de la covariable. Si la covariable tuviera más de dos categorías, entonces aumentaría el número de estratos en la misma cantidad que el número de categorías de la covariable. Por otra parte, si quisiéramos estratificar por dos covariables dicotómicas, entonces el primer estrato estaría formado por la categoría "0" en cada covariable, el segundo estrato por la categoría "1" en la covariable "A" y la categoría "0" en la covariable "B", el tercero por la categoría "0" en la covariable "A" y la categoría "1" en la covariable "B", y el cuarto estrato por la categoría "1" en las dos covariables.

3. Para cada estrato se calcula el estadístico de interés, que podrá ser RA, RR u OR.
4. Los estadísticos calculados para cada estrato se ponderan mediante un estimador ajustado. Las estimaciones ajustadas de RR y OR se pueden calcular mediante varios procedimientos, de los cuales el de Mantel-Haenszel (fórmula 25,6 para RR y 25,14 para OR) es el más conocido. El ajuste de RA, al igual que los de RR y OR, se puede realizar mediante el método directo (fórmula 25,1 para RA, 25,9 para RR y 25,17 para OR).
5. Continuamos evaluando las interacciones entre covariables. Para hacerlo, dirigimos nuestro interés a las estimaciones de interés (RA, RR, OR) en cada estrato: si fueran muy diferentes, concluiríamos que existe interacción y los estimadores de cada estrato deberán presentarse por separado. Al evaluar la interacción, lo hacemos mediante una prueba chi-cuadrada (fórmula 25,5 para RA, 25,13 para RR y 25,21 para OR). Se considera que la interacción es estadísticamente significativa cuando $p \leq 0.05$.
6. Si se descarta interacción, se procederá a comparar los estimadores crudo y ajustado. Si los dos estimadores son semejantes, se considerará que la asociación entre la variable independiente y la variable dependiente no está confundida. Sin embargo, si los dos estimadores son sustancialmente diferentes, se considerará que la covariable confunde la asociación. Para el caso de RR y de OR, se considera que existe confusión cuando la diferencia entre la estimación cruda y la ajustada es mayor de 10%. Este criterio no se aplica al análisis con RA.
7. Las estimaciones ajustadas podrán presentarse en el mismo cuadro que las estimaciones crudas, para lo cual

Cuadro 25-6. Acomodo de datos para un análisis estratificado de tres variables con 2 × 2 × 4 celdas

Estrato 1			Estrato 2		
Exposición	Enfermo	No enfermo	Exposición	Enfermo	No enfermo
Sí	a_1	b_1	Sí	a_2	b_2
No	c_1	d_1	No	c_2	d_2
Estrato 3			**Estrato 4**		
Exposición	Enfermo	No enfermo	Exposición	Enfermo	No enfermo
Sí	a_3	b_3	Sí	a_4	b_4
No	c_3	d_3	No	c_4	d_4

© Editorial El Manual Moderno Fotocopiar sin autorización es un delito.

se tendrían que agregar dos columnas más (una para los estimadores ajustados y otra para sus intervalos de confianza), o bien podrían presentarse en un cuadro separado. En cualquiera de los dos casos será necesario que en las notas al pie de cuadro se definan las covariables que están incluidas en el estimador ajustado.

Fórmulas para el análisis estratificado

RA mediante ajuste directo

$$RA_{Directo} = e^{\left(\frac{\sum_{i=1}^{s} w_i \ln(RA_i)}{\sum_{i=1}^{s} w_i}\right)} \tag{25,1}$$

donde

$$w_i = \frac{1}{\frac{a_i b_i}{(a_i+b_i)^3} + \frac{c_i d_i}{(c_i+d_i)^3}} \tag{25,2}$$

$$RA_i = \frac{a_i}{a_i+b_i} - \frac{c_i}{c_i+d_i} \tag{25,3}$$

Intervalo de confianza

$$RA_{Directo} \pm \frac{Z_{1-\alpha/2}}{\sqrt{\sum_{i=1}^{s} w_i}} \tag{25,4}$$

Prueba de interacción

$$\chi^2_{n-1} = \sum_{i=1}^{s} \frac{\left[RA_i - RA_{Directo}\right]^2}{Var(RA_i)} \tag{25,5}$$

donde $Var(RA_i) = 1/w_i$

RR mediante Mantel-Haenszel

$$RR_{MH} = \frac{\sum_{i=1}^{s} \frac{a_i n_{0i}}{n_i}}{\sum_{i=1}^{s} \frac{b_i n_{1i}}{n_i}} \tag{25,6}$$

Intervalo de confianza

$$OR_{MH} e^{\pm Z_{1-\alpha/2} \mathrm{EE}(\ln RR_{MH})} \tag{25,7}$$

donde

$$EE(\ln RR_{MH}) = \sqrt{\frac{\sum_{i=1}^{s} \left[(a_i+c_i)(a_i+b_i)(c_i+d_i) - a_i c_i n_i\right]/n_i^2}{\left[\sum_{i=1}^{s} \frac{a_i(c_i d_i)}{n_i}\right]\left[\sum_{i=1}^{s} \frac{c_i(a_i b_i)}{n_i}\right]}} \tag{25,8}$$

RR mediante ajuste directo

$$RR_{Directo} = e^{\left(\frac{\sum_{i=1}^{s} w_i \ln(RR_i)}{\sum_{i=1}^{s} w}\right)} \tag{25,9}$$

donde

$$w_i = \frac{1}{\frac{c_i}{a_i n_i} + \frac{d_i}{b_i n_i}} \tag{25,10}$$

$$RR_i = \frac{a_i/a_i + b_i}{c_i/c_i + d_i} \tag{25,11}$$

Intervalo de confianza

$$RR_{Directo} e^{\left(\frac{\pm Z_{1-\alpha/2}}{\sqrt{\sum_{i=1}^{s} w_i}}\right)} \tag{25,12}$$

Prueba de interacción

$$\chi^2_{n-1} = \sum_{i=1}^{s} \frac{\left[\ln(RR_i) - \ln(RR_{Directo})\right]^2}{Var\left[\ln(RR_i)\right]} \tag{25,13}$$

donde Var [ln(RRi)]=1/w_i

OR mediante Mantel-Haenszel

$$OR_{MH} = \frac{\sum_{i=1}^{s} \frac{a_i d_i}{n_i}}{\sum_{i=1}^{s} \frac{b_i c_i}{n_i}} \tag{25,14}$$

Intervalo de confianza

$$OR_{MH} e^{\pm Z_{1-\alpha/2} \mathrm{EE}(\ln OR_{MH})} \tag{25,15}$$

donde

$$EE(\ln OR_{MH}) = \sqrt{\frac{\sum_{i=1}^{s} P_1 R_1}{2\left[\sum_{i=1}^{s} R_i\right]^2} + \frac{\sum_{i=1}^{s} (P_i S_i + Q_i R_i)}{2\sum_{i=1}^{s} R_i \sum_{i=1}^{s} S_i} + \frac{\sum_{i=1}^{s} Q_1 S_1}{2\left[\sum_{i=1}^{s} S_i\right]^2}} \tag{25,16}$$

cuando

$$P_i = (a_i + d_i)/n_i$$
$$Q_i = (b_i + c_i)/n_i$$
$$R_i = a_i d_i / n_i$$
$$S_i = b_i c_i / n_i$$

© Editorial El Manual Moderno Fotocopiar sin autorización es un delito.

OR mediante ajuste directo

$$OR_{Directo} = e^{\left(\frac{\sum_{i=1}^{s} w_i OR_i}{\sum_{i=1}^{s} w}\right)} \quad (25,17)$$

donde

$$w_i = \frac{1}{\frac{1}{a_i}+\frac{1}{b_i}+\frac{1}{c_i}+\frac{1}{d_i}} \quad (25,18)$$

$$OR_i = \frac{a_i d_i}{b_i c_i} \quad (25,19)$$

Intervalo de confianza

$$OR_{Directo} e^{\left(\frac{\pm Z_{1-\alpha/2}}{\sqrt{\sum_{i=1}^{s} w_i}}\right)} \quad (25,20)$$

Prueba de interacción

$$\chi^2_{n-1} = \sum_{i=1}^{s} \frac{\left[\ln(OR_i) - \ln(OR_{Directo})\right]^2}{Var\left[\ln(OR_i)\right]} \quad (25,21)$$

donde Var [ln(ORi)]=1/w_i

CONFUSIÓN E INTERACCIÓN CUANDO LA VARIABLE DEPENDIENTE ES DICOTÓMICA

Confusión

El concepto de confusión con variables dependientes dicotómicas es semejante al descrito para el caso de la regresión múltiple (capítulo 24). Así, para que una covariable confunda la asociación entre la variable independiente y la variable dependiente, el factor de confusión deberá estar asociado con la variable dependiente y con la variable independiente, y no debe ser un eslabón intermedio de la cadena causal entre la variable independiente de interés y la variable dependiente. Al igual que para la regresión múltiple, el estimador crudo, o inicial, se comparará con el estimador ajustado (que tomará en cuenta al posible factor de confusión). Cuando los dos estimadores (crudo y ajustado) sean semejantes, se considerará que no existe confusión. Por otra parte, cuando los dos estimadores sean diferentes, se podrá concluir que sí existe confusión.

En este momento del análisis surge la pregunta: ¿qué tanto tendrán que ser diferentes los estimadores crudo y ajustado para asegurar que existe confusión? Esta pregunta no siempre es fácil contestar. Para el caso de RR y de OR, una gran cantidad de investigadores consideran que la diferencia porcentual entre ambos estimadores deberá ser de 10% o mayor. Este criterio, sin embargo, no es estricto, ya que diferencias porcentuales menores pueden ser consideradas como evidencia de confusión cuando se sabe (por estudios previos) que ésta se asocia con la exposición (variable independiente) y con el efecto (variable dependiente).

Interacción

En términos generales, el concepto de interacción con variables dependientes dicotómicas es semejante al descrito para el caso de la regresión múltiple (capítulo 24), ya que también se refiere al hecho de que la asociación entre la exposición y el evento final de estudio pudiera variar según la presencia y/o magnitud de un tercer factor. Sin embargo, ante un mismo grupo de datos, la evaluación de la interacción será diferente según el estimador (RA, RR o OR) que se esté utilizando. Cuando no se identifica interacción para uno de ellos, con frecuencia se presenta para uno o dos de los restantes. A manera de ejemplo se presentan los **cuadros 25-7**, **25-8** y **25-9**. El primero se refiere a los datos de una investigación ficticia que tiene el mismo RA para cada estrato (RA = 0.27). En este caso, la significancia de la interacción será mayor de .05. Esta conclusión coincide con la que se obtendría al comparar el riesgo relativo que, aunque no es el mismo para cada estrato (1.80 en el primero, 3.89 en el segundo), la interacción

Cuadro 25-7. Análisis estratificado que muestra interacción para el estimador OR

		Enfermedad			
	Exposición	sí	no		
Estrato 1	sí	150	100	RA	0.27
	No	500	1000	RR	1.80
				OR	3.00
Estrato 2	Sí	112	200	RA	0.27
	No	509	5000	RR	3.89
				OR	5.50
Total	Sí	262	300		
	No	1009	6000		
RA crudo	0.32		*P* de interacción		
RA ajustado	0.27		0.99		
RR crudo	3.24				
RR ajustado	2.58		0.56		
OR crudo	5.19				
OR ajustado	4.19		0.00		

© Editorial El Manual Moderno Fotocopiar sin autorización es un delito.

Cuadro 25-8. Análisis estratificado que muestra interacción para los estimadores RA y OR

		Enfermedad			
	Exposición	sí	no		
Estrato 1	sí	150	100	RA	0.27
	no	500	1000	RR	1.80
				OR	3.00
Estrato 2	sí	120	500	RA	0.09
	no	602	5000	RR	1.80
				OR	1.99
Total	sí	270	600		
	no	1102	6000		
RA crudo	0.16		*p* de interacción		
RA ajustado	0.11		0.00		
RR crudo	2.00				
RR ajustado	1.80		1.00		
OR crudo	2.45				
OR ajustado	2.33		0.02		

Cuadro 25-9. Análisis estratificado que muestra interacción para el estimador RA

		Enfermedad			
	Exposición	sí	no		
Estrato 1	sí	150	100	RA	0.27
	no	500	1000	RR	1.80
				OR	3.00
Estrato 2	sí	150	500	RA	0.14
	no	500	5000	RR	2.54
				OR	3.00
Total	sí	300	600		
	no	1000	6000		
RA crudo	0.19		*p* de interacción		
RA ajustado	0.16		0.00		
RR crudo	2.33				
RR ajustado	2.13		0.79		
OR crudo	3.00				
OR ajustado	3.00		1.00		

no alcanza a ser estadísticamente significativa para el tamaño de muestra que se presenta. Sin embargo, cuando se toma en cuenta el OR de cada estrato (3.00 para el primero, 5.50 para el segundo), concluimos que sí existe interacción ($p < .01$). De manera semejante, los **cuadros 25-8** y **25-9** muestran otros dos estudios donde RR u OR se mantienen constantes para

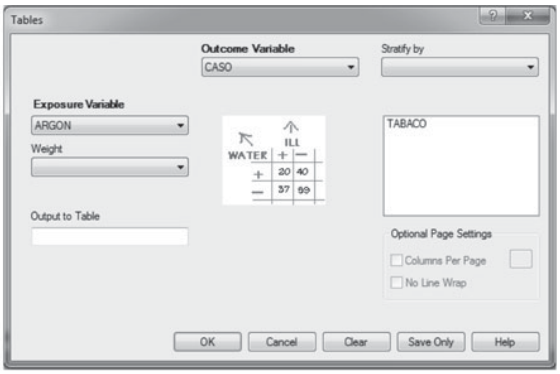


Figura 25-1. Ventana de opciones de la orden "Tables".

cada estrato y no existe interacción para esos estimadores, pero sí para uno o dos de los otros.

Este comportamiento, al parecer caótico, se explica con facilidad al notar que los tres estimadores se calculan de manera diferente: el RA se calcula mediante una sustracción, y el criterio de la interacción es aditivo, mientras que el RR y el OR son razones donde el criterio de interacción es multiplicativo. Estos dos, aunque se evalúan en la misma escala multiplicativa, pueden ser diferentes, porque la escala de OR no siempre es igual, o próxima, a la de RR.

Cómo hacerlo en Epi Info, 25-1

En Epi Info, el análisis estratificado puede realizarse de dos maneras: en "Analyze Data" o en "StatCalc".

1. Para hacerlo en "Analyze Data", entre al módulo, abra el archivo Bioestadística_3ra y seleccione la tabla Bio3_25a, que representa los datos de un estudio de casos y controles. Para calcular el OR crudo, proceda como se describe en "Cómo hacerlo en Epi Info, 6-2". Para realizar el análisis estratificado, seleccione nuevamente el comando "Tables" para definir las variables de interés: "ARGON" como "Exposure Variable" y "CASO" como "Outcome Variable". Además, definimos una o varias variables, como podría ser "TABACO" en "Stratify by", las que después de ser seleccionadas se podrán observar en la ventana que se encuentra debajo de esta opción (como se aprecia en la **figura 25-1**).

   Al hacer click con el ratón en "OK", en la ventana de resultados podrá encontrar un cuadro 2 x 2 (GEN y CASO) para cada estrato de TABACO. Para nuestro ejemplo serían tres cuadros, uno para el estrato "0", otro para el estrato "1" y otro para el estrato "2" de la covariable "TABACO". Cada cuadro muestra sus estimaciones de OR y RR, así como sus intervalos de confianza y pruebas estadísticas. Después de estos cuadros se

© Editorial El Manual Moderno Fotocopiar sin autorización es un delito.

mostrará el resumen del análisis (figura 25-2), donde encontraremos:

1. Las estimaciones crudas y ajustadas del OR, así como sus intervalos de confianza, calculadas con varios procedimientos diferentes.
2. Las estimaciones crudas y ajustadas del RR, así como sus intervalos de confianza, calculadas con varios procedimientos diferentes.
3. Las pruebas estadísticas (tests estadísticos) chi-cuadrada para la significancia del análisis estratificado.

   Como se supone que los datos proceden de un estudio de casos y controles, los únicos estimadores que podemos tomar en cuenta para este ejemplo serán los de OR, e ignoraremos los de RR.

2. El análisis estratificado también puede realizarse en el módulo de Statcalc. Para hacerlo, se procede de manera semejante a lo revisado en el inciso tres de "Cómo hacerlo en Epi Info, 6-2" hasta que, después de anotar las frecuencias de cada celda en el primer estrato, obtenemos los resultados que se muestran en la figura 25-3. Para el segundo estrato, hacemos clic en la ceja "Strata 2" y anotamos los datos del segundo estrato (figura 25-4). Luego, hacemos clic en el siguiente estrato para completar los datos (figura 25-5). Al introducir los datos en todos los estratos, se notará que el programa mostrará el resumen de resultados ("Summary Results"). Al comparar las figuras 25-2 y 25-5, notará que presentan resultados muy semejantes (aunque no necesariamente iguales).

SUMMARY INFORMATION

Parameters	Point Estimate	95%Confidence Interval Lower	Upper
Odds Ratio Estimates			
Crude OR (cross product)	3.1150	1.9309,	5.0254 (T)
Crude (MLE)	3.1084	1.9272,	5.0450 (M)
		1.8781,	5.1836 (F)
Ajusted OR (MH)	2.9413	1.8082,	4.7845 (R)
Ajusted OR (MLE)	3.0713	1.8236,	5.2155 (F)
Risk Ratios (RR)			
Crude Risk Ratio (RR)	1.6276	1.2602,	2.1021
Adjusted RR (MH)	1.5880	1.2299,	2.0502

(T=Taylor series; R=RGB; M=Exact mid-P; F=Fisher exact)

STATISTICAL TESTS (overall association)	Chi-square	1-tailed p	2-tailed p
MH Chi-square - uncorrected	21.0489		0.0000
MH Chi-square - corrected	19.8792		0.0000

Figura 25-2. Ventana de resultados de la orden "Tables".

Análisis ajustado mediante regresión logística

La regresión logística es uno de los procedimientos estadísticos más utilizados por los investigadores epidemiológicos

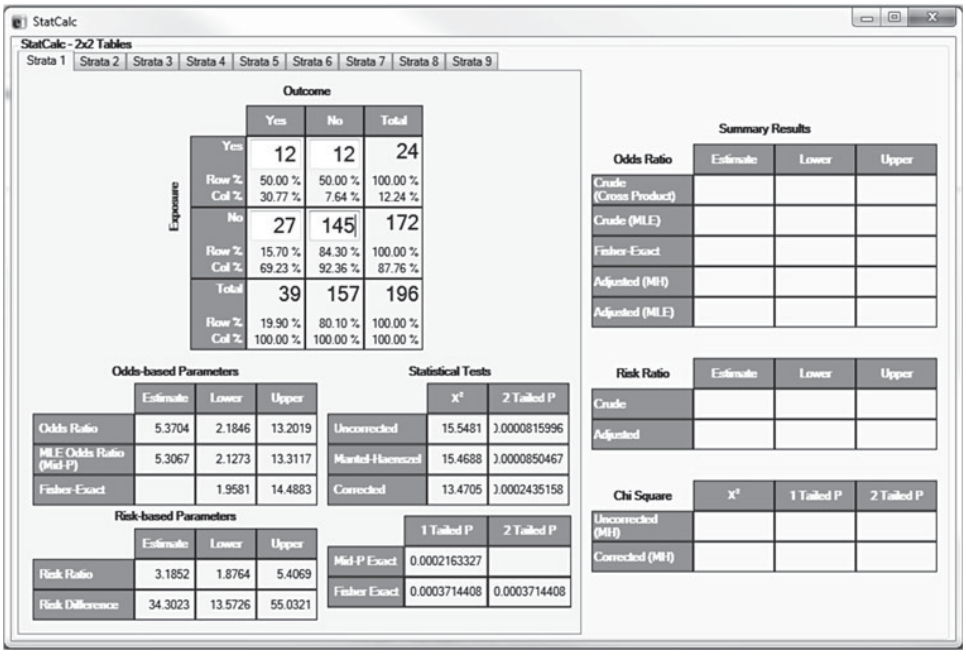


Figura 25-3. Primer estrato.

© Editorial El Manual Moderno Fotocopiar sin autorización es un delito.

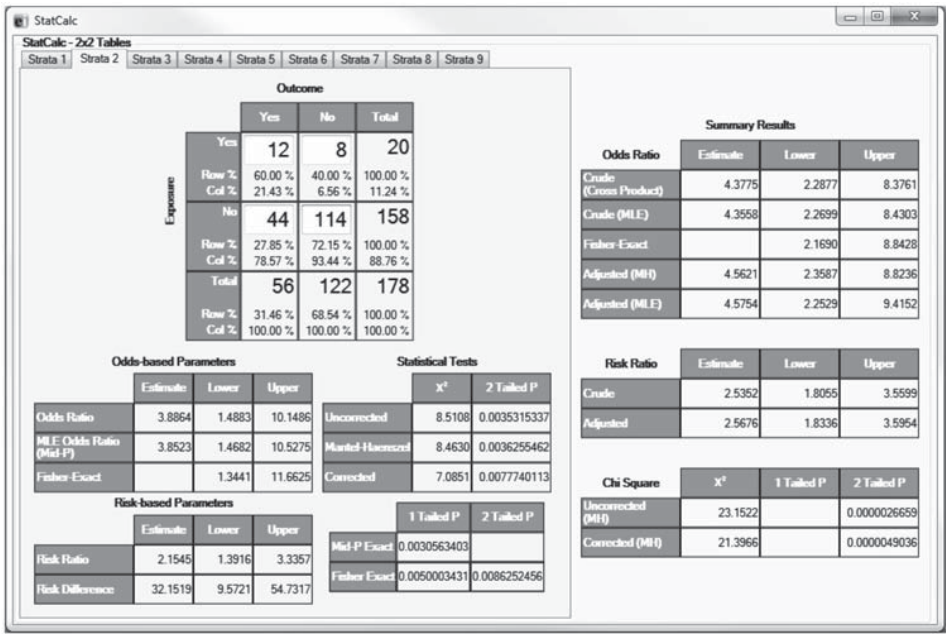


Figura 25-4. Segundo estrato.

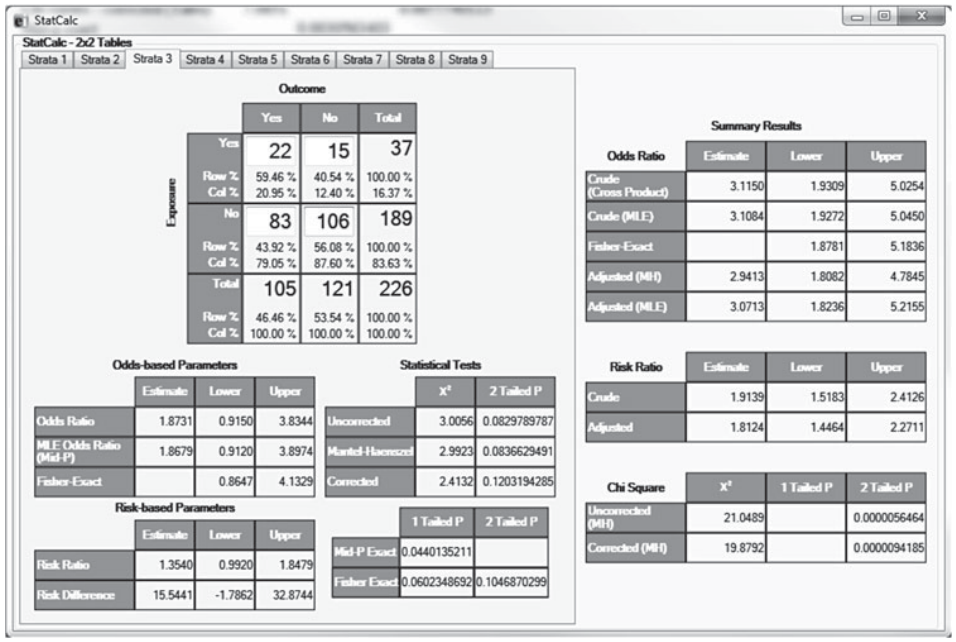


Figura 25-5. Tercer y último estrato.

en las últimas dos décadas del siglo XX, y probablemente lo seguirá siendo por muchos años más en este siglo XXI. La manera en que se utiliza tiene muchos elementos comunes con la regresión múltiple, y constantemente nos estaremos refiriendo a lo descrito en el capítulo 24, aunque la regresión logística tiene particularidades importantes que la distinguen y le dan su propia personalidad.

La regresión logística se utiliza con mucha frecuencia para analizar datos cuando las variables dependiente e independiente son dicotómicas y han sido codificadas como "1" cuando los sujetos tienen la característica de interés y "0" cuando no la tienen. Dada la complejidad de las operaciones que el procedimiento demanda, para el cálculo de los coeficientes de la regresión se utiliza un programa de cómputo como Epi Info.

© Editorial El Manual Moderno Fotocopiar sin autorización es un delito.

Cómo hacerlo en Epi Info, 25-2

Para realizar una regresión logística en Epi Info 7, llame al módulo "Analyze Data", abra el archivo Bioestadística_3ra y seleccione la tabla Bio2_25a, que representa los datos de un estudio de casos y controles.

Seleccione la opción "Logistic Regression" en el apartado "Advanced Statistics". En la ventana de diálogo que se despliega, seleccione "CASO" en "Outcome Variable" y "ARGON" en "Other Variables". En ese momento, la ventana deberá observarse como en la figura 25-6.

Al hacer clic en "OK", podrá encontrar lo siguiente en la ventana de resultados (figura 25-7):

1. Odds ratio.
2. Intervalo de confianza de 95%.
3. Coeficiente de regresión.
4. Error estándar de los coeficientes.
5. Valor de z.
6. Significancia estadística de los coeficientes.
7. Estadísticos del procedimiento propiamente dicho.
8. Pruebas de hipótesis del modelo en conjunto.

Si el mismo análisis lo realiza con el comando "Tables", utilizando "ARGON" como variable independiente y "CASO" como variable dependiente (figura 25-8), encontrará que el odds ratio calculado mediante razón de productos cruzados, sus intervalos de confianza calculados mediante Serie de Taylor y la significancia (valor de *p*) calculada mediante chi-cuadrada sin corrección serán los mismos.

MODELO DE REGRESIÓN LOGÍSTICA

Un elemento fundamental de la regresión logística es la función logística

$$f(z) = \frac{1}{1+e^{-z}} \qquad (25,22)$$

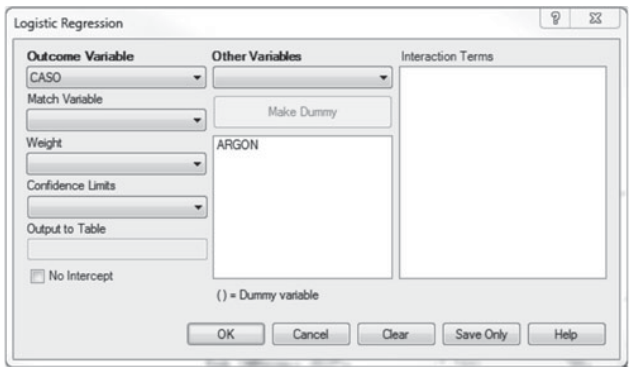


Figura 25-6. Ventana del comando "Logistic Regression".

Unconditional Logistic Regression

Term	Odds Ratio	95%	C.I.	Coefficient	S.E.	Z-Statistic	P-Value
ARGON (Yes/No)	3.1150	1.9309	5.0253	1.1362	0.2440	4.6566	0.0000
CONSTANT	*	*	*	-0.8629	0.0961	-8.9806	0.0000

Convergence:	Converged
Iterations:	4
Final-2*Log-Likelihood:	741.9612
Cases included:	600

Test	Statistic	D.F.	P-Value
Score	23.1856	1	0.0000
Likelihood Ratio	21.8559	1	0.0000

Figura 25-7. Resultados de la orden "Logistic Regression".

donde *e* denota la función exponencial y *z* es cualquier cantidad que se encuentre entre -∞ y +∞. Mediante esta ecuación, cualquier cantidad asignada a *z* se transformará en un número entre 0 y 1. Ésta es una característica muy conveniente cuando se trata de calcular probabilidades, como es el caso de las estimaciones de riesgo en la investigación epidemiológica.

La forma de la función logística es otra de las características que la han hecho muy útil para el análisis multivariado en epidemiología, porque este modelo establece un umbral de riesgo que puede aplicarse a una gran variedad de condiciones de salud-enfermedad. Como puede observarse en la figura 25-9, donde se aprecia que cuando *z* es igual a menos infinito el valor de f(z) es igual a 0, a medida que el valor de *z* aumenta

	CASO		
ARGON	0	1	Total
0	365	154	519
Row%	70.33%	29.67%	100.00%
Col%	91.25%	77.00%	86.50%
1	35	46	81
Row%	43.21%	56.79%	100.00%
Col%	8.75%	23.00%	13.50%
TOTAL	400	200	600
Row%	66.67%	33.33%	100.00%
Col%	100.00%	100.00%	100.00%

Single Table Analysis

	Point Estimate	95% Confidence Interval Lower	Upper	
PARAMETERS: Odds-based				
Odds Ratio (cross product)	3.1150	1.9309	5.0254	(T)
Odds Ratio (MLE)	3.1084	1.9272	5.0450	(M)
		1.8781	5.1836	(F)
PARAMETERS: Risk-based				
Risk Ratio (RR)	1.6276	1.2602	2.1021	(T)
Risk Difference (RD%)	27.1177	15.6361	38.5993	(T)

(T=Taylor series; C=Cornfield; M=Mid-P; F=Fisher exact)

STATISTICAL TESTS	Chi-square	1-tailed p	2-tailed p
Chi-square - uncorrected	23.1856		0.0000026402
Chi-square - Mantel-Haenszel	23.1470		0.0000026700
Chi-squere - corrected (Yates)	21.9814		0.0000039223
Mid-p exact		0.0000016706	
Fisher exact		0.0000025588	0.0000034796

Figura 25-8. Resultados de la orden "Tables".

© Editorial El Manual Moderno Fotocopiar sin autorización es un delito.

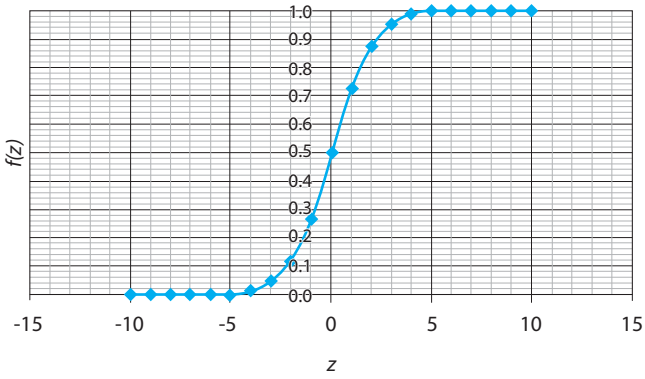


Figura 25-9. Diagrama de la función logística.

también lo hace el valor de *f(z)*, al principio muy lentamente hasta que *z* se encuentra cercano a 0 y la pendiente del gráfico cambia de dirección rápidamente, de tal manera que al llegar a *z* = 0 el valor de *f(z)* es igual a 0.5. A partir de este punto, el trazo de la pendiente sigue un patrón semejante hasta que *f(z)* es igual a 1 cuando *z* es igual a +∞.

A partir de la función logística, obtenemos el modelo logístico mediante la sustitución *z* por $\beta_0 + \beta_1X_1 + \beta_2X_2 + \beta_kX_k$, de modo que

$$f(z) = \frac{1}{1+e^{-z}} = \frac{1}{1+e^{-(\beta_0+\beta_1X_1+\beta_2X_2+\ldots+\beta_kX_k)}} \qquad (25,23)$$

donde los coeficientes β son estimados mediante un procedimiento conocido como máxima verosimilitud (o maximum likelihood, en inglés). Cuando estos coeficientes son conocidos, podemos, mediante el modelo logístico, calcular la probabilidad de que un individuo presente un evento de interés –si la variable dependiente es dicotómica– utilizando la fórmula

$$P(Y=1 \mid X_1, X_2, \ldots, X_k) = \frac{1}{1+e^{-(\beta_0+\beta_1X_1+\beta_2X_2+\ldots+\beta_kX_k)}} \qquad (25,24)$$

Una expresión alternativa del modelo logístico se representa mediante

$$\ln\left(\frac{P(y)}{1-P(y)}\right) = \beta_0 + \beta_1X_1 + \beta_2X_2 + \ldots + \beta_kX_k \qquad (25,25)$$

donde $\ln\left(\frac{P(y)}{1-P(y)}\right)$ se puede leer como "logit de *P*(*y*)".

Ejemplo explicativo 25-3

Tomemos el **cuadro 25-8**. Cuando hacemos que "X" sea la variable independiente (ARGON) y situamos sus categorías (SÍ, NO) en los renglones, al tiempo que "Y" es la variable dependiente y colocamos sus categorías (caso, control) en las columnas, y calculamos las proporciones que corresponden a cada celda según el total de cada renglón, obtendremos un arreglo semejante al **cuadro 25-10**.

Cuando estos mismos datos se utilizan en una regresión logística, se obtienen los resultados que se muestran en la **figura 25-7**, donde el coeficiente de ARGON (β_1) es igual a 1.1362 y el de la constante (β_0) es igual a -0.8629. Con estos valores y la ecuación 25,24, podremos calcular la probabilidad de que en la muestra se seleccione un sujeto que tenga la característica Y = 1 cuando X = 1 mediante

$$P(Y=1 \mid X=1) = \frac{1}{1+e^{-(-0.8629)+1.1362(1))}} = 0.568$$

De manera semejante, la probabilidad de que en la muestra se seleccione un sujeto que tenga la característica Y = 1 cuando X = 0 será igual a

$$P(Y=1 \mid X=1) = \frac{1}{1+e^{-(-0.8629)+1.1362(0))}} = 0.297$$

Como podrá apreciarse, los resultados en el cálculo de probabilidad son los mismos que los mostrados en el **cuadro 25-10**.

Cuando los datos proceden de un diseño de cohorte o de un ensayo clínico, la probabilidad calculada mediante la fórmula 25,24 corresponde a una incidencia acumulada. Pero no ocurre así cuando los datos proceden de un estudio de casos y controles. No obstante, los resultados de la regresión logística también pueden utilizarse para calcular odds ratios, se trate de un diseño de cohorte, de casos y controles o de estudio transversal. Para hacerlo, recordemos que, cuando las frecuencias se acomodan en un cuadro 2 x 2, el odds ratio se calcula mediante ad/bc, sin importar que se utilicen frecuencias absolutas o relativas. De esta manera, para los datos del **cuadro 25-10**.

$$\varphi = \frac{46 \times 365}{35 \times 154} = \frac{0.568 \times 0.703}{0.432 \times 0.297} = 3.115$$

Entonces, si representamos cada celda con la fórmula para calcular la probabilidad de interés, obtendremos un

Cuadro 25-10. Distribución de frecuencias y porcentajes de renglón en un cuadro 2 × 2

Variable	Casos		Controles	
	n	*P* (renglón)	n	*P* (renglón)
ARGON				
Sí	46	0.568	35	0.432
No	154	0.297	365	0.703

© Editorial El Manual Moderno Fotocopiar sin autorización es un delito.

arreglo como el que se muestra en el **cuadro 25-11**, a partir del cual podremos calcular el odds ratio mediante

$$\varphi = \frac{ad}{cb} = \frac{\left(\frac{e^{\beta_0+\beta_{1X1}}}{1+e^{\beta_0+\beta_{1X1}}}\right)\left(\frac{1}{1+e^{\beta_0}}\right)}{\left(\frac{e^{\beta_0}}{1+e^{\beta_0}}\right)\left(\frac{1}{1+e^{\beta_0+\beta_{1X1}}}\right)} = \frac{e^{\beta_0+\beta_1}}{e^{\beta_0}} = e^{\beta_1} \qquad (25{,}26)$$

Interpretación de los coeficientes de regresión

En la sección anterior, encontramos que (como conclusión de la ecuación 25,6) el exponente de un coeficiente de regresión logística es igual al odds ratio. Este ejemplo puede extenderse para incluir más de una variable independiente en la ecuación, de tal manera que

$$\varphi = \frac{e^{\beta_0+\beta_1X_1+\beta_2X_2+\ldots\beta_kX_k}}{e^{\beta_0+\beta_1X_1+\beta_2X_2+\ldots\beta_kX_k}} \qquad (25{,}27)$$

Antes de continuar es necesario recordar que

$$\frac{e^a}{e^b} = e^{a-b} \qquad (25{,}28)$$

Ejemplo explicativo 25-4

Para poder utilizar la fórmula 25,27 es necesario que se cuente con los coeficientes obtenidos mediante regresión logística, como los que se muestran en la **figura 25-10**, conseguidos a partir de la tabla de datos Bioestadistica3_25a que utilizamos anteriormente en este mismo capítulo. Para obtener los mismos valores, sólo será necesario repetir el ejemplo presentado en "Cómo hacerlo en Epi Info 25-2" seleccionando las variables independientes ARGON y ALCOHOL. Estas dos variables fueron codificadas con 1 siempre que: ARGON = SÍ y ALCOHOL = SÍ. En caso contrario, se codificó 0.

A partir de estos resultados, utilizando las fórmulas 25,27 y 25,28 podemos calcular el odds ratio para cualquier combinación de exposiciones. Por ejemplo, el riesgo de bajo peso al nacer en el grupo expuesto a hipertensión arterial durante el embarazo será igual a

$$\varphi = e^{[-1.0730+1.1569(1)+0.5648(0)]-[-1.0730+1.1569(0)+0.5648(0)]}$$

$$= e^{1.1569} = 3.1802$$

$$= e^{[-1.0730+1.1569(1)+0.5648(1)]-[-1.0730+1.1569(0)+0.5648(1)]} = e^{1.1569}$$

Para el cálculo de los intervalos de confianza, cuando el análisis no muestra evidencia de interacción, se utilizará la fórmula genérica

estimador puntual ± nivel de confianza (error estándar)

donde el nivel de confianza está definido por $Z_{1-\alpha/2}$. De esta manera, el intervalo de confianza de 95% sería igual a

$$\text{IC95\%: } e^{\beta \pm Z_{1-0,05/2}(\text{SE})} = e^{1.1569 \pm 1.96(0.2464)}$$

Límite inferior, $e^{0.6740}$=1.9619; límite superior, $e^{1.6398}$ = 5.1550,

Unconditional Logistic Regression

Term	Odds Ratio	95%	C.I.	Coefficient	S.E.	Z-Statistic	P-Value
ARGON (Yes/No)	3.1802	1.9616	5.1550	1.1569	0.2464	4.6945	0.0000
ALCOHOL (Yes/No)	1.7591	1.2283	2.5194	0.5648	0.1833	3.0817	0.0021
CONSTANT	*	*	*	-1.0730	0.1210	-8.8651	0.0000

Convergence:	Converged
Iterations:	4
Final-2*Log-Likelihood:	732.4961
Cases included:	600

Test	Statistic	D.F.	P-Value
Score	32.4080	2	0.0000
Likelihood Ratio	31.3209	2	0.0000

Figura 25-10. Resultados de la orden "Logistic Regression".

Cuadro 25-11. Cálculos de probabilidades para cada celda según la fila en un cuadro 2 x 2

	Y	
X	1	0
1	$\frac{1}{1+e^{-(\beta_0+\beta_1X_1)}} = \frac{e^{\beta_0+\beta_1X_1}}{1+e^{\beta_0+\beta_1X_1}}$	$1-\frac{1}{1+e^{-(\beta_0+\beta_1X_1)}} = \frac{1}{1+e^{\beta_0+\beta_1X_1}}$
0	$\frac{1}{1+e^{-(\beta_0)}} = \frac{e^{\beta_0}}{1+e^{\beta_0}}$	$1-\frac{1}{1+e^{-(\beta_0)}} = \frac{1}{1+e^{\beta_0}}$

© Editorial El Manual Moderno Fotocopiar sin autorización es un delito.

Variables cualitativas y cuantitativas

Las variables independientes en regresión logística se manejan de manera semejante en regresión múltiple:

- Las variables cualitativas dicotómicas (que sólo tienen dos categorías) se codifican utilizando los valores 1 y 0.
- Las variables cualitativas con más de dos categorías se codifican generando variables dummy, tal como se hace en regresión múltiple (véase capítulo 24). En estas condiciones, el conjunto de variables dummy que representan una variable ha de entrar y salir del modelo en conjunto, a menos que se decida cambiar el criterio de codificación.
- Las variables cuantitativas pueden incluirse como tales en el modelo de regresión siempre que muestren una relación lineal con el aumento del coeficiente de regresión, tal como se ilustra en la **figura 25-11A**. En caso contrario, como sería el caso de la **figura 25-11B**, la variable numérica podrá transformarse, o bien agruparse en categorías y manejarse como variable cualitativa utilizando variables dummy.

Pruebas de hipótesis en regresión logística

Al igual que para el caso de regresión múltiple, en regresión logística se tienen varias opciones de prueba de hipótesis: una basada en la función de verosimilitud, asociada a la distribución chi-cuadrada; y otra conocida como prueba de Wald, con base en la distribución normal.

De la función de verosimilitud se calculan dos momentos: uno inicial, V_I, y otro final, V_F. Ambos valores son menores de 1, y $V_I < V_F$. Con ambos números se puede calcular la devianza, o *D*, mediante la fórmula

$$D = -2\ln\left(\frac{V_I}{V_F}\right) \qquad (25{,}29)$$

La característica más importante de *D*, en términos de una prueba de hipótesis, es su distribución, pues lo hace como la variable χ^2 con *k* grados de libertad. La ecuación 25,29 también puede escribirse como

$$D = \left[-2\ln(V_I)\right] - \left[-2\ln(V_F)\right] \qquad (25{,}30)$$

La fórmula 25,30 es más conveniente que la fórmula 25,29 porque frecuentemente los programas de cómputo brindan $-2\ln(V_I)$ y $-2\ln(V_F)$ en lugar de V_I y V_F como parte de sus resultados. Mediante la razón de verosimilitud, o *R*, podremos probar la hipótesis nula de que una o más de las variables independientes incluidas en el modelo son iguales a 0.

Cuando el interés se dirige a una prueba parcial (es decir, a sólo algunas de las variables incluidas en el modelo), la ecuación 25,30 se modifica un poco para incluir las verosimilitudes finales de cada modelo a comparar,

$$D = \left[-2\ln(V_{F*})\right] - \left[-2\ln(V_F)\right] \qquad (25{,}31)$$

que se distribuye como χ^2 con $K - K^*$ grados de libertad, donde el asterisco identifica al modelo con el menor número de variables.

La prueba de Wald utiliza el estadístico *Z* y la distribución normal para probar la hipótesis nula de que un coeficiente en particular, β, es igual a 0. El valor de *Z* se calcula dividiendo el valor del coeficiente entre su error estándar, y el resultado se compara con los valores de la distribución normal. Esta prueba es útil cuando se tiene interés en la significancia de una variable cuantitativa o de una variable cualitativa dicotómica, pero no es útil cuando estamos interesados en la evaluación simultánea de la significancia de dos o más coeficientes, como es el caso de una prueba de hipótesis múltiple parcial.

Cómo hacerlo en Epi Info, 25-3

Desde "Analyze Data" abra el archivo Bioestadistica_3da y seleccione la tabla Bio3_25a. Elija la opción "Logistic Regression" y en la ventana de diálogo que se despliega

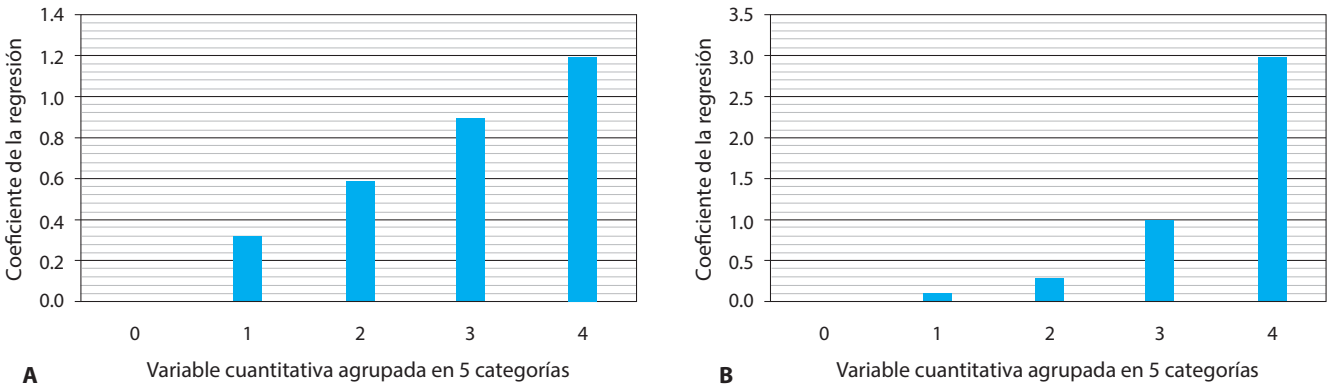


Figura 25-11. Variable cuantitativa agrupada en cinco categorías. La figura "A" muestra linealidad, mientras que la figura "B" no tiene linealidad.

© Editorial El Manual Moderno Fotocopiar sin autorización es un delito.

seleccione "CASO" en "Outcome Variable" y "ALCOHOL" y "ARGON" en "Other Variables". Después de hacer clic en "OK", obtendrá los resultados que se muestran en la **figura 25-10**.

Al final de los resultados mostrados en la **figura 25-10**, encontraremos dos pruebas de hipótesis del modelo ("Score" y "Likelihood Ratio"). Ambas están probando la hipótesis nula $\beta_1 = \beta_2 = \ldots = \beta_k = 0$. Compare los resultados de la **figura 25-10** con los de la **figura 25-7** y ponga atención en los grados de libertad. En los resultados de la **figura 25-7** sólo se tiene 1 grado de libertad, porque el modelo sólo incluye una variable independiente (ARGON), mientras que el modelo de la **figura 25-10** tiene dos grados de libertad, porque están incluidas dos variables independientes (ARGON y ALCOHOL).

Observe también que los resultados muestran V_F (Final-2*log-Likelihood), pero no V_I. Con este valor se puede probar que la hipótesis nula $\beta_{ALCOHOL}$ es igual a 0, una vez que la variable ARGON ya está incluida en el modelo. Para hacerlo, tomamos el valor de $V_{F*} = 741.9612$ y le restamos $V_F = 732.4961$. Comparamos la diferencia, 9.4651, con el valor crítico de $\chi^2_{0.95}$ del Anexo G (que para un grado de libertad es igual a 3.84). Como el valor calculado es mayor que el valor tabulado, rechazamos la hipótesis nula.

Entre los resultados de la regresión logística, el de la prueba de Wald se muestra en la columna "Valor de Z". Cuando éste corresponde a una variable cuantitativa o a una cualitativa dicotómica, el resultado es semejante al obtenido mediante la comparación de verosimilitudes. No ocurre así cuando la prueba de hipótesis se realiza con una variable cualitativa con más de dos categorías, que se representa en el modelo mediante dos o más variables dummy. En este último caso, el resultado de la prueba de Wald es difícil de interpretar, particularmente cuando la prueba en una de las variables dummy es significativa y en la otra no.

Interacción

La interacción en regresión logística se evalúa de manera semejante a la realizada en regresión múltiple. Es decir, con las variables de interés se genera una nueva variable que es el producto de sus valores. Esta nueva variable se agrega al modelo que incluye las variables que se están evaluando. Si el coeficiente de la nueva variable que resultó del producto de las otras es significativo, entonces se considera que existe interacción, la cual se deberá incluir en el modelo final. En caso de que la interacción no sea significativa, la variable de la interacción no se incluirá en el modelo final.

Es necesario señalar que, a diferencia de la regresión múltiple, en la regresión logística la interacción que se evalúa está en una escala multiplicativa y no aditiva. Para los fines del modelo matemático no existen más implicaciones, pero es necesario revisar algún texto avanzado de epidemiología para identificar las diferencias conceptuales que existen entre los modelos aditivos y multiplicativos de riesgo.

Cómo hacerlo en Epi Info, 25-4

Desde "Analyze Data" abra el archivo Bioestadistica_3ra y seleccione la tabla Bio3_25a. Elija la opción "Logistic Regression" en "Advanced Statistics". En la ventana de diálogo que se despliega, seleccione "CASO" en "Outcome Variable" y "ARGON" y "GEN" en "Other Variables". Luego haga clic en las etiquetas "ARGON" y "GEN" en la ventana de "Other Variables". Al hacerlo, las variables serán resaltadas mediante una barra azul. Cuando las dos estén seleccionadas, el botón "Make Dummy" cambiará a "Make Interaction". Al hacer clic en "Make Interaction", la expresión "ARGON*GEN" se agregará a la ventana de "Interaction Terms". En ese momento, la ventana de diálogo se encontrará como lo muestra la **figura 25-12**. Después de hacer clic en "OK", obtendrá los resultados que se muestran en la **figura 25-13**, donde se podrá observar que el coeficiente de la interacción de "ARGON*GEN" si es estadísticamente significativo.

Cuando el análisis multivariado muestre que existe interacción entre dos o más variables, los resultados de la misma deberán presentarse señalando el riesgo para cada combinación posible de exposición a las variables incluidas en la interacción, como se presenta en el **cuadro 25-12**.

Para su elaboración, procedemos de la siguiente manera: el OR para el grupo no expuesto a GEN ni a ARGON, que es el grupo de referencia, es 1.0. Para el grupo expuesto a GEN pero no a ARGON, así como para el grupo expuesto a ARGON pero no a GEN, tomamos los OR y sus intervalos de confianza de los resultados de la **figura 25-12**. Pero el OR de la interacción GEN*ARGON que presenta la **figura 25-12** no corresponde al resultado que se anotará en el cuadro. Para obtener este valor de OR, es necesario utilizar la fórmula 25-27, que para este caso tendría la forma

$$\varphi = \frac{e^{\beta_0 + \beta_{argon}(X_{argon}) + \beta_{gen}(X_{gen}) + \beta_a}}{e^{\beta_0 + \beta_{argon}(X_{argon}) + \beta_{gen}(X_{gen}) + \beta_a}}$$

$$\varphi = \frac{e^{-1.2627 + 0.3311(1) + 1.3718(1) + 2.3686(1)(1)}}{e^{-1.2627 + 0.3311(0) + 1.3718(0) + 2.3686(0)(0)}}$$

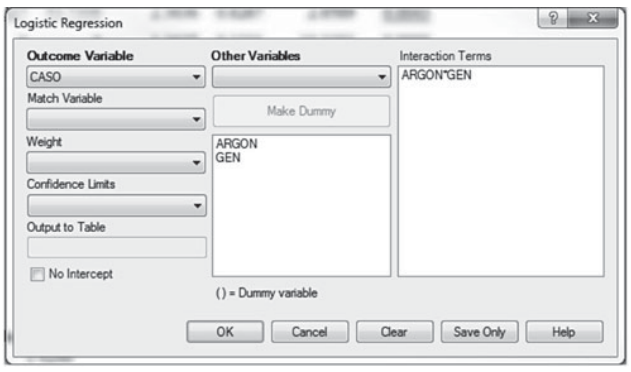


Figura 25-12. Ventana de opciones de la orden "Logistic Regression" que incluye una interacción.

© Editorial El Manual Moderno Fotocopiar sin autorización es un delito.

Unconditional Logistic Regression

Term	Odds Ratio	95%	C.I.	Coefficient	S.E.	Z-Statistic	P-Value
ARGON (Yes/No)	1.3925	0.7020	2.7624	0.3311	0.3495	0.9474	0.3434
GEN (Yes/No)	3.9405	2.5880	6.0000	1.3713	0.2145	6.3926	0.0000
ARGON (Yes/No) * GEN (Yes/No)	10.6292	2.1027	53.7308	2.3636	0.8267	2.8589	0.0043
CONSTANT	*	*	*	-1.2627	0.1221	-10.3383	0.0000

Convergence:	Converged
Iterations:	6
Final-2*Log-Likelihood:	660.0549
Cases included:	600

Test	Statistic	D.F.	P-Value
Score	103.1877	3	0.0000
Likelihood Ratio	103.7621	3	0.0000

Odds Ratios for ARGON * GEN Interaction

Label	Estimate	95% Confidence Limits	
ARGON No vs Yes at GEN=No	0.7181	0.3620	1.4246
ARGON No vs Yes at GEN=Yes	0.0676	0.0156	0.2934

Figura 25-13. Resultados de la orden "Logistic Regression" que incluye una interacción.

El intervalo de confianza para el OR de la interacción que se aprecia en el renglón ARGON(Yes/No)*GEN(Yes/No) tampoco corresponde. Su cálculo es algo más complejo, principalmente porque la fórmula para hacerlo incluye algunos valores de covarianza que pocos programas de cómputo proporcionan (Epi Info no los incluye).

Este problema puede simplificarse si se aborda de otra manera. Para obtener el intervalo de confianza que nos haría falta en el **cuadro 25-12**, podemos generar una nueva variable (que podrá llamarse ARGON_GEN, por ejemplo) donde definiremos cuatro categorías: 0 para ARGON = no, GEN = no; 1 para ARGON = sí, GEN = no; 2 para ARGON = no, GEN = sí; y 3 para ARGON = sí, GEN = sí. Luego realizamos la regresión logística sustituyendo las variables ARGON y GEN por la nueva variable ARGON_GEN, que deberá definirse por medio de variables dummy. Los resultados de la regresión logística se muestran en la **figura 25-14**, entre los que se podrá identificar el OR de la interacción (58.3) y sus intervalos de confianza de 95% (13.7, 247.9).

Es necesario recordar que esta variable (ARGON_GEN), creada a partir de las variables ARGON y GEN, ha ingresado a la ecuación como una variable dummy, y que de ella no se pueden eliminar categorías sin cambiar la codificación de las variables originales. De ser necesario, la nueva variable podrá incluirse en un modelo multivariado que permita identificar y controlar otras variables que podrían confundir su asociación con la variable dependiente.

Cuadro 25-12. Cuadro de resultados que muestra los OR de la interacción y sus intervalos de confianza de 95%

Exposición a			
ARGON	GEN	OR	IC 95%
No	No	1.0	
Sí	No	1.4	0.7 a 2.8
No	Sí	3.9	2.6 a 6.0
Sí	Sí	58.3	13.3 a 247.9

Confusión

El concepto de confusión, así como el control de las variables que la introducen, es semejante al de la regresión múltiple y al expresado líneas arriba en relación con el análisis estratificado. Para identificar un factor de confusión, es necesario comparar el coeficiente de la variable posiblemente confundida de dos modelos: uno que no incluye el posible factor de confusión y otro que sí lo incluye. Si ambos coeficientes son semejantes, se

Unconditional Logistic Regression

Term	Odds Ratio	95%	C.I.	Coefficient	S.E.	Z-Statistic	P-Value
ARGON_GEN(1/0)	1.3925	0.7020	2.7624	0.3311	0.3495	0.9474	0.3434
ARGON_GEN (2/0)	3.9405	2.5880	6.0000	1.3713	0.2145	6.3926	0.0000
ARGON_GEN (3/0)	58.3256	13.7204	247.9428	4.0660	0.7384	5.5069	0.0000
CONSTANT	*	*	*	-1.2627	0.1221	-10.3383	0.0000

Convergence:	Converged
Iterations:	6
Final-2*Log-Likelihood:	660.0549
Cases included:	600

Test	Statistic	D.F.	P-Value
Score	103.1877	3	0.0000
Likelihood Ratio	103.7621	3	0.0000

Figura 25-14. Resultado con la variable ARGON_GEN que se formó con las variables ARGON y GEN para estimar los intervalos de confianza de la interacción.

© Editorial El Manual Moderno Fotocopiar sin autorización es un delito.

considerará que no existe confusión. Sin embargo, si la diferencia entre los dos coeficientes es distinta, se considerará que sí existe confusión y la variable confundidora deberá mantenerse en el modelo de regresión logística independientemente de la significancia estadística que muestra la variable que confunda. Se considera que una diferencia cercana o mayor de 10% en el cambio del coeficiente indica confusión.

Estrategias de análisis multivariado

En este momento es importante destacar que la selección de las variables para un análisis multivariado debe apoyarse en un marco teórico o conceptual coherente. De otra manera, sólo se convertirá en una excursión de pesca.

Aclarado lo anterior, el análisis multivariado mediante regresión logística implica varias etapas que deben tomarse en cuenta. Las primeras dos ya han sido descritas al principio de este capítulo, e incluyen la comparación de los grupos estudiados, con el objetivo de mostrar que son comparables o de identificar sesgos potenciales, y el análisis crudo. Las siguientes etapas corresponden a la identificación de las variables que se incluirán en el análisis, la obtención de un modelo inicial que incluya las variables pertinentes, la búsqueda de interacciones, la identificación de factores de confusión y la bondad de ajuste del modelo definitivo.

- Identificación de las variables que se incluirán. Para definir la lista de variables candidatas, se deberán considerar todas aquellas que tengan un nivel de significancia menor de 0.25. A estas variables también se deberán agregar aquellas que tengan alguna importancia en relación con la variable dependiente o con las variables independientes más importantes.
- Después de definir la lista de variables candidatas para el modelo multivariado, se identificarán las variables que tengan una importancia estadísticamente significativa en el modelo. Para hacerlo, el modelo se podrá construir agregando variables a partir de aquella que muestra la mayor asociación. Alternativamente se podrá integrar un modelo con todas las variables candidatas y, poco a poco, retirar aquellas que muestren la menor asociación. La agregación o eliminación de variables a partir del modelo inicial podrá hacerse individualmente o en grupo. Es necesario recordar que las variables dummy formadas a partir de aquellas con más de dos categorías deberán ser incluidas o retiradas en grupo, a menos que el investigador decida modificar su codificación.
- Para seleccionar las variables con las que se definirá el modelo, se deberán tomar en cuenta, al menos, dos aspectos: la significancia estadística y la probable confusión que introduzcan en las asociaciones de interés. El primer criterio se basará en la significancia estadística y se identificará mediante las pruebas de Wald o las razones de verosimilitud. Además, e independientemente del criterio anterior, el modelo múltiple también deberá incluir aquellas variables que muestran un efecto confusor. En otras palabras, si durante el análisis se encuentra que una variable es factor de confusión, esa variable ha de incluirse en el modelo, sin importar su significancia estadística dentro de él.
- Es necesario tomar en cuenta que no es indispensable incluir en el modelo todas las variables que sean estadísticamente significativas. Con frecuencia, sólo tenemos interés en estudiar la relación de una variable independiente con una variable dependiente. En este caso, el modelo estará formado por las dos variables de interés (independiente y dependiente) y por aquellas covariables que interactúen o confundan a la variable independiente. Otras variables, aunque tengan una asociación estadísticamente significativa con la variable dependiente, podrán ser excluidas del modelo y, quizá, analizarse en otro momento.
- Una vez obtenido el modelo que incluya las variables esenciales, deberemos prestar atención a las variables cuantitativas, sobre todo a su linealidad, en los términos descritos en la sección de "Variables cualitativas y cuantitativas".
- Al igual que para el caso de la regresión múltiple, un aspecto importante en relación con las covariables es la colinealidad.
- Luego es necesario explorar la interacción que pudiera existir entre variables.
- Después identificamos las variables confusoras.
- Concluimos evaluando la bondad de ajuste del modelo.

Ejemplo explicativo 25-5

Consideremos los datos de la tabla Bio3_25a del archivo Bioestadistica_3ra con los que se han presentado los ejemplos de este capítulo de cómo hacerlo en Epi Info 7. Supongamos que nuestro interés primario es describir la asociación de las variables independientes en estudio con la condición de caso. Las variables incluidas en esta base de datos tienen los siguientes códigos: enfermo (CASO), 1 = sí, 0 = no; alcoholismo (ALCOHOL), 1 = sí, 0 = no; exposición a gas argón (ARGON), 1 = sí, 0 = no; presencia del gen en estudio (GEN), 1 = sí, 0 = no; grupo de edad (EDAD), 0 = menor de 30 años, 1 = 30 a 44 años, 2 = 45 y más años; sexo del paciente (SEXO), 1 = hombre, 0 = mujer; exposición al humo de tabaco (TABACO), 0 = no, 1 = fumador pasivo, 2 = fumador activo.

El análisis bivariado (**cuadro 25-13**) nos muestra que cuatro de las seis variables son candidatas a incorporarse al modelo multivariado (las variables "EDAD" y "SEXO" no las consideraremos para el análisis multivariado porque tienen una valor de $p > 0.25$).

Una regresión logística (**figura 25-15**) que incluya en el mismo modelo las cuatro variables con valor de significancia < 0.25 del **cuadro 25-13** nos hace ver que la variable "ALCOHOL" pierde su significancia estadística (pasa de $p = 0.0025$ en el modelo bivariado a $p = 0.9178$ en el modelo multivariado) y su estimación de riesgo (mediante OR) pasa de 1.72 a 1.03 (una reducción de más de 10%). Este cambio podría ser explicado porque la variable ALCOHOL es confundida a causa de alguna de las otras variables del modelo. Más adelante, tocaremos este tema con mayor detalle. Por lo pronto, la excluiremos del análisis en nuestro ejemplo.

© Editorial El Manual Moderno Fotocopiar sin autorización es un delito.

Después de identificarlas como significativas en el modelo multivariado, buscamos interacciones entre las tres variables restantes. Cuando la muestra es lo suficientemente grande y las relaciones entre las variables así lo permiten, es factible que exploremos más de una interacción en un solo procedimiento, tal como se muestra en los resultados de la **figura 25-16**.

Los resultados de la regresión logística que se muestran en la **figura 25-16** nos permiten identificar la existencia de interacción entre las variables ARGON y GEN, pero no entre ARGON y TABACO ni entre GEN y TABACO. Así que, después de retirar las interacciones no significativas, el modelo final es el que aparece en la **figura 25-17**.

Para este momento del análisis, quizá ya encontró algunas particularidades en los resultados que llaman la atención. En primer lugar, el hecho de que la variable ALCOHOL, que era estadísticamente significativa en el análisis crudo, no es estadísticamente significativa en el análisis multivariado; así que concluimos que estaba confundida a causa de alguna de las covariables que están incluidas en el modelo multivariado. Para saber cuál es la(s) variable(s) confusora(s), tendremos que comparar el riesgo crudo con el riesgo ajustado por las otras covariables, tal como se muestra en el **cuadro 25-14**, donde notaremos que la variable confusora sería TABACO.

También podemos notar que la variable ARGON, una vez que tenemos su interacción con GEN en el modelo (**figura 25-17**), pierde significancia estadística ($p = 0.41$). Este resultado nos podría hacer pensar que deberíamos excluirla del modelo y dejar sólo la interacción, pero eso no es posible, porque una vez que hemos decidido que una interacción es significativa, todas las variables que se incluyen en esa interacción deberán mantenerse en el modelo.

Al final, podremos concluir que el modelo que mejor estima el riesgo es el que se muestra en la **figura 25-17**.

Cuadro 25-13. OR y nivel de significancia estadística para la asociación de las variables con la condición de caso

Variable	OR	Asociación con la condición de caso (*p*)
ALCOHOL	1.72	0.0025
ARGON	3.12	<0.0001
GEN	5.46	<0.0001
EDAD		0.9726
30 a 44 años	0.89	
≥ 45 años	1.00	
SEXO (Hombre)	0.90	0.5253
TABACO		<0.0001
Fumador(a) pasivo(a)	1.85	
Fumador(a) activo(a)	3.49	

Unconditional Logistic Regression

Term	Odds Ratio	95%	C.I.	Coefficient	S.E.	Z-Statistic	P-Value
ALCOHOL (Yes/No)	1.0266	0.6232	1.6913	0.0263	0.2547	0.1032	0.9178
ARGON (Ye/No)	2.6126	1.5316	4.4565	0.9603	0.2725	3.5245	0.0004
GEN (Yes/No)	5.2933	3.5171	7.9666	1.6664	0.2086	7.9896	0.0000
TABACO (1/0)	1.5766	0.9445	2.6315	0.4552	0.2614	1.7416	0.0816
TABACO (2/0)	3.4072	1.944	5.9708	1.2259	0.2862	4.2831	0.0000
CONSTANT	*	*	*	-2.0082	0.2129	-9.4321	0.0000

Convergence:	Converged
Iterations:	5
Final-2*Log-Likelihood:	641.8174
Cases included:	600

Test	Statistic	D.F.	P-Value
Score	119.0226	5	0.0000
Likelihood Ratio	121.9996	5	0.0000

Figura 25-15. Resultados del comando "Logistic Regression".

Unconditional Logistic Regression

Term	Odds Ratio	95%	C.I.	Coefficient	S.E.	Z-Statistic	P-Value
ARGON (Yes/No)	2.7628	0.9068	8.4173	1.0162	0.5684	1.7879	0.0738
GEN (Ye/No)	2.6009	1.0658	6.3471	0.9559	0.4552	2.1000	0.0357
TABACO (1/0)	1.5701	0.7968	3.0940	0.4511	0.3461	1.3035	0.1924
TABACO (2/0)	3.3637	1.8550	6.0995	1.2131	0.3037	3.9948	0.0001
ARGON (Yes/No) * GEN (Yes/No)	10.1202	1.9663	52.0868	2.3145	0.8359	2.7688	0.0056
ARGON (Yes/No) * TABACO (1/0)	0.7146	0.1387	3.6809	-0.3361	0.8363	-0.4018	0.6878
ARGON (Yes/No) * TABACO (2/0)	0.2465	0.0573	1.0609	-1.4004	0.7447	-1.8806	0.0600
GEN (Yes/No) * TABACO (1/0)	1.4515	0.4669	4.5125	0.3726	0.5787	0.6439	0.5197
GEN (Yes/No) * TABACO (2/0)	2.2562	0.7321	6.9533	0.8137	0.5743	1.4169	0.1565
CONSTANT	*	*	*	-1.9012	0.2480	-7.6675	0.0000

Figura 25-16. Resultados de la orden "Logistic Regression" que incluye la evaluación simultánea de tres interacciones.

© Editorial El Manual Moderno Fotocopiar sin autorización es un delito.

Unconditional Logistic Regression

Term	Odds Ratio	95%	C.I.	Coefficient	S.E.	Z-Statistic	P-Value
ARGON (Yes/No)	1.3484	0.6659	2.7303	0.2989	0.3600	0.8304	0.4063
GEN (Yes/No)	4.0233	2.5967	6.2335	1.3921	0.2234	6.2314	0.0000
TABACO (1/0)	1.6301	0.9667	2.7488	0.4886	0.2666	1.8328	0.0668
TABACO (2/0)	3.5215	2.1752	5.7011	1.2589	0.2458	5.1214	0.0000
ARGON (Yes/No) * GEN (Yes/No)	11.0081	2.1294	56.9081	2.3986	0.8382	2.8617	0.0042
CONSTANT	*	*	*	-1.9336	0.2129	-9.0833	0.0000

Convergence:	Converged
Iterations:	6
Final-2*Log-Likelihood:	630.2285
Cases included:	600

Test	Statistic	D.F.	P-Value
Score	127.5923	5	0.0000
Likelihood Ratio	133.5885	5	0.0000

Figura 25-17. Resultados de la orden "Logistic Regression" que incluye la evaluación de una interacción.

Bondad de ajuste

Evaluar la bondad de ajuste del modelo en que hemos concluido es una parte importante del análisis, aunque con frecuencia se omite. De manera general, la bondad de ajuste evaluará si el modelo que hemos obtenido refleja los datos de los que hemos partido. Para hacerlo, existen varias pruebas estadísticas y presentaciones gráficas. Por lo general, éstas son complejas y requieren de software especializado (SPSS, Egret). Sin embargo, una manera sencilla de llevarlo a cabo consiste en comparar las frecuencias observadas de "Y" (variable dependiente) iguales a "1" con las esperadas a partir del modelo. Para hacerlo, procedemos según el siguiente ejemplo explicativo.

Ejemplo explicativo 25-6

Supóngase que después de analizar los datos hemos concluido que los resultados que se muestran en la **figura 25-17** corresponden al modelo que consideramos más adecuado para representar las asociaciones que se estudian. A partir de esos resultados, evaluamos la bondad de ajuste de este modelo de la siguiente manera:

1. Calculamos la probabilidad de presentar el evento de interés que cada individuo tiene a partir de la combinación de factores de riesgo. Para hacerlo, utilizamos la fórmula 25,24

$$P(Y=1)=\frac{1}{1+e^{-(z)}}$$

Donde z = -1.9336 + 0.2989 (argon) + 1.3921 (gen) + 0.4886 (tabaco_1) + 1.2589 (tabaco_2). El cálculo de cada valor de P (Y = 1) se puede realizar fácilmente en una hoja de cálculo; hay que recordar que la variable TABACO tiene que representarse mediante variables dummy (TABACO_1, TABACO_2).

2. Con los valores de cada individuo, se agrupan tal como se presenta en el **cuadro 25-15**.
3. El **cuadro 25-15** se puede simplificar para presentar sólo las frecuencias esperadas y observadas de cuatro grupos, como se muestra en el **cuadro 25-16**.
4. Por último, las frecuencias observadas y esperadas del **cuadro 25-16** se comparan para cada grupo de probabilidad. Como puede apreciarse, las frecuencias esperadas y observadas no son muy diferentes, así que concluimos que la ecuación tiene una bondad de ajuste más o menos adecuada. La prueba de Hosmer y Lemeshow en SPSS (que mide la bondad de ajuste) con los mismos datos nos daría una significancia estadística de .53, donde lo que se busca es aceptar la hipótesis nula ($p > .05$).

Cómo hacerlo en Epi Info, 25-5

Para evaluar la bondad de ajuste en los términos descritos en la sección anterior, será necesario:

1. Definir ("Define") las variables dummy necesarias según sea el caso cuando el modelo incluya variables con más de dos categorías. En nuestro ejemplo, la variable "TABACO" deberá transformarse en las variables indicadoras (dummy): "TABACO_1" = 1 cuando "TABACO" sea igual a 1 y "TABACO_1"=0 cuando "TABACO" tenga otro valor diferente a 1, "TABACO_2" = 1 cuando "TABACO" sea igual a 2 y "TABACO_2" = 0 cuando "TABACO" tenga otro valor.
2. Definir ("Define") una nueva variable ("P") en la tabla de datos, donde se registrará la probabilidad (utilizando la fórmula 25,24) de cada individuo de presentar el evento.
3. Tabular ("Frequency") la nueva variable "P" para saber cuántos sujetos tiene cada probabilidad calculada en el paso anterior (columna "Total" del **cuadro 25-15**).

© Editorial El Manual Moderno Fotocopiar sin autorización es un delito.

Cuadro 25-15. Comparación de frecuencias observadas y esperadas para evaluar la bondad de ajuste de un modelo de regresión logística

P	Total	E	O	P	Total	E	O
0.13	141	18.33	19	0.41	19	7.79	6
0.16	16	2.56	4	0.44	8	3.52	8
0.19	108	20.52	21	0.49	50	24.5	23
0.24	11	2.64	3	0.56	9	5.04	9
0.34	141	47.94	46	0.67	48	32.16	37
0.37	31	11.47	8	0.73	18	13.14	16

P: Probabilidad de ser casos según la combinación de factores de riesgo.
Total: Incluye a todos los sujetos que presentan la misma probabilidad de ser casos.
E: Esperados. Se calcula multiplicando el valor de P por el Total.
O: Observados. Incluye a todos los sujetos que son casos con el mismo valor de P.

4. Después, para calcular la columna de esperados (columna "E" en el cuadro 25-15), multiplicamos la probabilidad (columna "P") por el total (columna "Total").
5. Para conocer la frecuencia observada, en Epi Info ejecutamos la orden "Tables" con las variables "P" y "Caso". El número de observados corresponderá a la frecuencia de casos para cada probabilidad.
6. Para terminar, sólo tendrían que agruparse las observaciones según el cuartil que corresponda y comparar las frecuencias observadas y esperadas (cuadro 25-16).

REGRESIÓN LOGÍSTICA CONDICIONAL

Siempre que la selección de casos y controles no sea independiente y que ambos grupos estén pareados por una o más variables, el análisis deberá considerar mantener el pareamiento. En estas condiciones, la elección inicial para la regresión logística será la condicional. Para poder realizarla, cada grupo de pareamiento deberá estar identificado con un número. Así, por ejemplo, uno de los grupos integrado por uno o más casos y uno o más controles se identificará con el número 1, el segundo grupo se identificará con el número 2 y así sucesivamente hasta completar el número de grupos pareados. La figura 25-18 muestra los datos de la tabla Bio3_25b, donde los sujetos estudiados fueron pareados según su edad, y la variable PAR identifica el grupo de pareamiento. Al revisar esa lista de datos, notará que por cada caso ("CASO" = 1) hay dos controles ("CASO" = 0) y que para cada grupo de pareamiento los tres sujetos tienen la misma exposición de "TABACO", que es la variable por la que fueron pareados.

Cuando los registros incluyen la variable que identifica al grupo de pareamiento, la regresión logística condicional en Epi Info se realiza de manera semejante a la regresión logística no condicional. Ambos procedimientos de regresión logística tienen diferencias importantes, aunque aquí sólo mencionaremos dos: para ejecutar una regresión logística condicional, será necesario definir cuál es la variable de apareamiento o "Matching variable", y el resultado que se despliega no mostrará el valor de β_0 (figura 25-19) que se muestra como la constante en la regresión logística no condicional. Estas dos diferencias no afectan la interpretación de los coeficientes de regresión, aunque no se podrá calcular valores de *P* mediante la ecuación 25,24.

El análisis pareado agrega una dificultad a la ejecución del análisis y a la interpretación de los resultados, por lo que en ocasiones nos preguntaremos si el pareamiento deberá

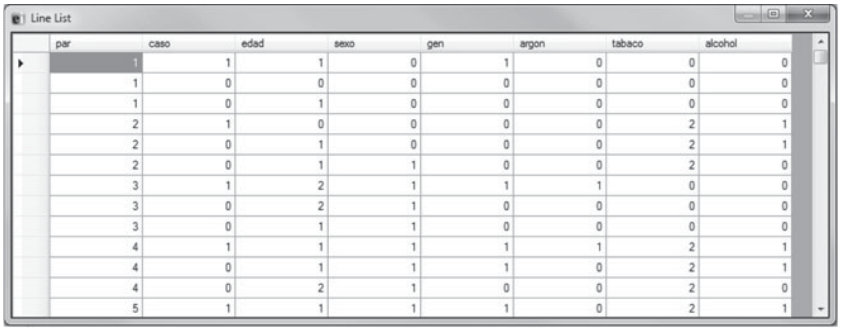
Cuadro 25-14. Cambio porcentual del OR de la variable alcohol según el ajuste de la covariable que se agrega al modelo

Variable que ajusta la estimación de OR de la variable ALCOHOL	OR de la variable ALCOHOL	Cambio porcentual
OR crudo (sin ajustar)	1.72	
ARGON	1.76	2.3%
GEN	1.87	8.7 %
TABACO	0.80	-53.5 %

Cuadro 25-16. Resumen en cuartiles de los datos mostrados en el cuadro 25-15

Probabilidad	Esperados	Observados
≤ 0.19	41.41	44
>0.19a ≤ 0.37	62.05	57
>0.37a ≤ 0.49	35.81	37
>0.49	50.34	62

© Editorial El Manual Moderno Fotocopiar sin autorización es un delito.



Line List

par	caso	edad	sexo	gen	argon	tabaco	alcohol
1	1	1	0	1	0	0	0
1	0	0	0	0	0	0	0
1	0	1	0	0	0	0	0
2	1	0	0	0	0	2	1
2	0	1	0	0	0	2	1
2	0	1	1	0	0	2	0
3	1	2	1	1	1	0	0
3	0	2	1	0	0	0	0
3	0	1	1	0	0	0	0
4	1	1	1	1	1	2	1
4	0	1	1	1	0	2	1
4	0	2	1	0	0	2	0
5	1	1	1	1	0	2	1

Figura 25-18. Listado de los primeros registros de la tabla de datos Bio3_25b.

Unconditional Logistic Regression

Term	Odds Ratio	95%	C.I.	Coefficient	S.E.	Z-Statistic	P-Value
alcohol (Yes/No)	1.1534	0.6481	2.0528	0.1428	0.2941	0.4854	0.6274

Convergence:	Converged
Iterations:	3
Final-2*Log-Likelihood:	219.4853
Cases included:	300

Test	Statistic	D.F.	P-Value
Score	0.2358	1	0.6272
Likelihood Ratio	0.2372	1	0.6262

Figura 25-19. Resultados de la orden "Logistic Regression" que considera una regresión logística condicional.

de mantenerse. Al respecto, podremos actuar de la siguiente manera: si al momento del muestreo la selección de los sujetos fue condicionada por un criterio de pareamiento, el análisis deberá iniciar como pareado; sin embargo, si se puede mostrar que los resultados pareados son semejantes a los que se obtienen sin tomar en cuenta el pareamiento, entonces el análisis podrá continuarse sin necesidad de mantener el pareamiento.

© Editorial El Manual Moderno Fotocopiar sin autorización es un delito.

Ejercicios

Los valores contenidos en Ejer_25a del archivo Bioestadística_3ra representan los datos de un estudio de casos y controles que exploró la relación que tienen cinco variables como factores de riesgo de asfixia por inmersión en el hogar sufrida por niños de 1 a 4 años de edad. "Pozo" y "Aljibe" igual a "1" significa que existían esos depósitos de agua en el hogar al momento del evento, "NSE" igual a "1" representa un "nivel socioeconómico bajo" y "0" corresponde a nivel medio o alto, "Edo_Civil" igual a "1" se refiere a soltera y "Edad_ma" igual a "1" se refiere a una madre menor de 20 años de edad. Con esos datos realice los siguientes análisis:

Ejercicio 1

Calcule los Odds Ratios crudos y ajustados que correspondan a las cuatro variables independientes y llene el cuadro 25-17 con los resultados. No olvide anotar los intervalos de confianza de 95% (IC95%) de cada OR.

Cuadro 23-17

Variable	Casos	Con-troles	ORc	IC 95%	ORa*	IC 95%
Edad de la madre						
< 20 años						
≥ 20 años						
Estado Civil						
Soltera						
Casada						
Nivel socioeconómico						
Bajo						
Medio o alto						
Aljibe en la vivienda						
Sí						
No						
Pozo de agua en la vivienda						
Sí						
No						

* El modelo ajustado incluye las cinco variables independientes.

Ejercicio 2

En el resultado del cuadro 25-17, sólo tres variables muestran una asociación estadísticamente significativa. Excluya las dos variables que no tienen una asociación estadísticamente significativa, y con las tres restantes llene el cuadro 23-18.

Cuadro 23-18

Variable	ORa*	IC95%

* El modelo ajustado incluye las tres variables.

Ejercicio 3

Evalúe las interacciones de esas tres variables y diga si son estadísticamente significativas.

Ejercicio 4

Si los datos son verdaderos, cuál es el riesgo de asfixia por inmersión de un niño que vive en un hogar con nivel socioeconómico bajo y que tiene pozo de agua comparado con un niño que vive en un hogar con nivel socioeconómico medio o alto y que no tiene aljibe.

REFERENCIAS

Calva-Mercado, J. J. (2000). Estudios clínicos experimentales. *Salud Pública de México*, *42*, 349-358.

Epi Info 7. CDC. Disponible en http://wwwn.cdc.gov/epiinfo/

Hosmer, D. W., & Lemeshow, S. (1989). *Applied Logistic Regression*. New York: John Wiley & Sons.

Kleinbaum, D. G. (1994). *Logistic Regression. A self-learning text*. New York: Springer.

Lazcano-Ponce, E., Fernández, E., Salazar-Martínez, E. y Hernández-Ávila, M. (2000). Estudios de cohorte. Metodología, sesgos y aplicaciones. *Salud Pública de México*, *42*, 230-241.

Lazcano-Ponce, E., Salazar-Martínez, E. y Hernández-Ávila, M. (2001). Estudios epidemiológicos de casos y controles. Fundamento teórico, variantes y aplicaciones. *Salud Pública de México*, *43*, 135-150.

Silva Ayçaguer, L. C. (1995). *Excursión a la Regresión Logística en Ciencias de la Salud*. Madrid: Díaz de Santos.

© Editorial El Manual Moderno Fotocopiar sin autorización es un delito.